

# 工业数字化转型：故障诊断方法研究进展

杨彪<sup>1,2</sup>, 熊贲<sup>1,2</sup>, 傅玲<sup>3</sup>, 徐蔚峰<sup>3</sup>, 李婧<sup>3</sup>

1. 复旦大学计算机科学技术学院, 上海, 200433;
2. 上海市数据科学重点实验室, 上海, 200433;
3. 西门子中国研究院, 北京, 100102

**摘要:** 工业数字化是我国工业产业转型升级的重要手段, 数字化转型成为我国工业发展的重要趋势。工业系统的可靠性和稳定性对工业生产的高质量和可持续发展具有重要作用。故障影响工业系统运行, 甚至造成重大的安全事故和经济损失。为应对这一问题, 故障诊断技术应运而生并逐步发展。高效、高质的故障诊断数字化技术已经成为工业数字化转型的关键技术。本文分析了工业领域故障诊断数字化方法的研究进展, 按照其发展划分为以领域经验主导的建模方法、数据驱动与领域经验结合的数字化方法、数据驱动主导与可解释性结合的数字化方法等三个阶段, 重点探究每个阶段方法的基本思想及其特点等, 并探讨未来的研究方向, 为推动工业数字化转型提供方法参考。

**关键词:** 工业数字化、数字化转型、故障诊断、数字化方法

中图分类号: TP311

文献标识码: A

doi: 10.11959/j.issn.2096-0271.2023041

## Industrial Digital Transformation: Research on Fault Diagnosis Digital Methods

YANG Biao<sup>1,2</sup>, XIONG Yun<sup>1,2</sup>, FU Ling<sup>3</sup>, XU Weifeng<sup>3</sup>, LI Jing<sup>3</sup>

1. School of Computer Science, Fudan University, Shanghai 200433, China
2. Shanghai Key Laboratory of Data Science, Shanghai 315100, China
3. Siemens Ltd., Beijing 100102, China

**Abstract:** Industrial digitalization is an important way for industrial transformation and upgrading of China's industry, and digital transformation has become an important trend in the development of China's industry. The reliability and stability of industrial systems play an important role in the

收稿日期: 2023-04-26

通信作者: yunx@fudan.edu.cn

基金项目: 上海市科委发展基金项目 (No.22DZ1200704)

**Foundation Items:** Shanghai Science and Technology Development Fund Projects (No.22DZ1200704)

high quality and sustainable development of industrial production. Failures affect the operation of industrial systems and even cause major safety accidents and economic losses. To deal with this problem, fault diagnosis technology was born and gradually developed. Efficient and high-quality fault diagnosis digital technology has become a key technology for industrial digital transformation. This paper analyzes the research progress of digital methods for fault diagnosis in industry, and divides them into three stages according to their development: domain experience-led modeling methods, data-driven digital methods combining with domain experience, and data-driven digital methods combining with interpretability. This paper focuses on exploring the basic ideas and characteristics of the methods in each stage, and discusses the future research directions to provide methodological references for promoting industrial digital transformation.

**Key words:** industrial digitization, digital transformation, fault diagnosis, digital methods

## 1 引言

工业数字化已经成为全球范围内的新型工业化趋势。在数字化工业中，企业利用数字化技术将生产流程和业务过程数字化，实现工业生产的自动化、自主化和智能化，从而提高生产效率和质量，降低成本和风险，实现可持续发展。

由于这些工业系统复杂化和高度集成化，一旦发生故障，可能会影响整个系统的运行，并引发扩散效应，出现生产停滞、资源浪费的情况，造成重大的安全事故和经济损失。通过故障诊断技术快速准确地确定设备故障及其原因并及时维修，将减少生产停滞和损失<sup>[1][2][3]</sup>。故障诊断数字化技术成为工业数字化转型的关键技术，对系统整体效能、产品生产质量等方面起着重要的提质增效作用，关于故障诊断数字化技术的研究逐步受到工业界和学术界的关注。

工业数字化转型经历了工业设备及其相关流程的数字化，积累了丰富的数据，进而通过数据驱动业务和管理。学界和业界对于如何更好的利用这些数据开展了研究和实践。本文聚焦故障诊断数字化方法的研究现状进行梳理，按照其发展特点划分为以领域经验主导的建模方法、数据驱动与领域经验结合的数字化方法、数据驱动主导与可解释性结合的数字化方法等三个阶段（如图 1）。故障诊断涉及的数据是多源、多类型的，例如传感器等设备获取系统运行过程中的时域信息和频域信息，包括振动信号、载荷信号、电路信号等；仪器仪表等智能终端实时采集的设备运行状态。这些数据在不同的阶段都有不同的处理方式。

在早期的领域经验主导阶段，故障诊断主要建模方法包括符号有向图(Signed Directed

Graph, SDG)、故障树(Fault Tree, FT)、Petri 网(Petri Nets, PN)和键合图(Bond Graph, BG)等, 这些算法在很大程度上依赖专业人员领域知识。随着数字化程度的发展以及工业数据的大量积累, 数据驱动与领域经验结合阶段更加注重对于数据特征及其关联的挖掘, 包括基于决策树(Decision Tree, DT)、支持向量机(Support Vector Machine, SVM)、贝叶斯网络(Bayesian Network, BN)等机器学习方法的故障诊断方法。工业系统运行数据不断积累, 呈现出多源、多模态等特性, 领域知识相对于获取的数据难以捕获潜在的数据特征。随着深度学习等数字化方法的发展, 催生出数据驱动主导的方法, 同时考虑到工业领域的可解释性, 研究者也开展了可解释性的研究, 这一阶段称为数据驱动主导与可解释性结合阶段。在这一阶段中, 深度学习的方法降低了对人工专家特征选择的依赖, 图神经网络(Graph Neural Network, GNN)等建模方法提供了具有可解释性的方案。

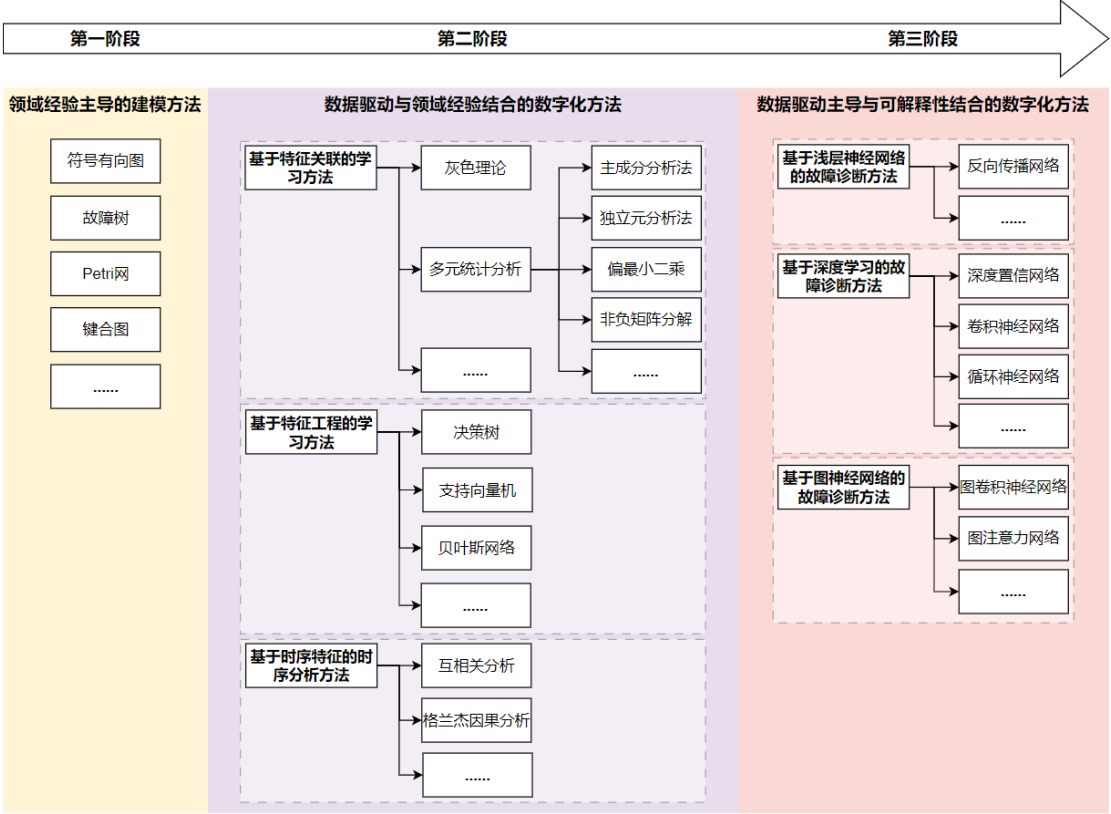


图1 各阶段的故障诊断方法

## 2 第一阶段：领域经验主导的建模方法

早期的领域经验主导阶段是依据专家经验, 用定性的思想分析工业流程中各个环节、各个单元之间的关系, 通常采用图论的方式进行建模, 包括符号有向图、故障树、Petri 网和键合图等。

符号有向图利用节点和有向边来描述系统的结构和功能, 建立变量之间的因果关系图<sup>[4]</sup>,

并结合推理策略解释故障传播路径<sup>[5]</sup>。Peng 等人<sup>[6]</sup>提出一种基于贝叶斯推理的多逻辑概率符号有向图模型，实现过程变量之间的因果表示。但是，当符号有向图用于描述复杂系统时，它的复杂结构限制了推理能力。为了简化图结构的复杂性，Liu 等人<sup>[7]</sup>引入规则矩阵和状态矩阵，Gang 等人<sup>[8]</sup>采用压缩节点、约束传播和中间优化技术建立基于分层的符号有向图模型。符号有向图方法能够根据因果关系图推理故障传播路径，但难以处理复杂逻辑关系，并且有向图的构建需要依赖人工经验。

故障树同样使用图对系统故障与它的各个部件之间的逻辑关系进行建模，例如，采用最小割集和最小路径等算法分析不同部件故障导致的系统故障<sup>[9]</sup>。Chen 等人<sup>[10]</sup>使用故障树对故障及其逻辑关系进行建模，然后从故障树中提取规则以识别故障。Wang 等人<sup>[11]</sup>提出基于故障配置的故障树生成方法，对系统故障进行建模分析。目前故障树方法存在有限的静态结构、不适于处理不确定性推理等问题，针对该问题，研究者利用故障树建模和贝叶斯网络推理能力等优点将故障树与贝叶斯网络结合实现故障诊断和推理<sup>[12][13][14]</sup>。故障树方法已被广泛应用，但该方法难以捕捉系统动态故障行为，不适于处理不确定性推理问题，高度依赖于专家经验。

Petri 网是一种图形化的建模方法，常被用于复杂、动态、并发和离散事件系统的建模任务<sup>[15]</sup>。Mansour 等人<sup>[16]</sup>将 Petri 网模型应用到电站故障诊断。Al-Ajeli 等人<sup>[17]</sup>使用带标签的 Petri 网对离散事件系统进行建模，捕获正常状态和错误行为。但是，上述方法只关注前向故障诊断而忽略了后向原因追溯<sup>[18]</sup>，Liu 等人<sup>[18]</sup>使用模糊证据推理 (Fuzzy Evidential Reasoning, FER) 方法和动态自适应模糊 Petri 网 (Dynamic Adaptive Fuzzy Petri Nets, DAFPNs) 来解决上述问题。在动态性方面，Zhang 等人<sup>[19]</sup>创建了时间推理模糊 Petri 网来处理时间约束和模糊信息，其模块化结构便于适应各种保护配置，适应拓扑变化。

键合图用于建模独立于系统参数值的结构化系统，该方法计算量较低，可以处理大规模系统<sup>[20]</sup>。Benmoussa 等人<sup>[20]</sup>利用双因果关系和因果路径的性质，从系统键合图中获得故障可检测性和可隔离性的结构条件。Badoud 等人<sup>[21]</sup>通过键合图对风力系统、涡轮系统进行建模，使用因果路径生成解析冗余关系，避免穷举所有组合以将其应用于故障诊断。目前，键合图模型在多故障诊断领域存在局限性，主要是在决策步骤的鲁棒性方面仍存在难点。对此，Chatti 等人<sup>[22]</sup>提出有符号键合图，综合利用结构特性，以消除可能存在的冲突。键合图模型计算量较低，但在大型复杂系统或多故障诊断领域的适应性较差。

在领域经验主导阶段中，符号有向图、故障树、Petri 网和键合图等故障诊断技术是通过领域知识和专家经验构建关联图，具有较好的可解释性和支持故障原因追溯。然而，这些方

法在缺乏先验知识的情况下难以应用于工业过程,同时对于变量之间因果关系的强弱以及时序动态性的考虑较为欠缺。

### 3 第二阶段:数据驱动与领域经验结合的数字化方法

如前所述,第一阶段中的方法需要依赖专业领域经验对相关数据进行关联建模,随着数据的增多,在构建变量之间因果关联图的过程中存在挑战。如何更好的利用数据,采用数据驱动的方法与领域经验结合,成为这一阶段研究的关键。通过数据驱动的方法发现因果拓扑关系,确定故障的特征,以实现故障诊断,主要包括基于特征关联的学习方法,基于特征工程的学习方法(例如,决策树、支持向量机、贝叶斯网络等),以及考虑时序特征的序列分析法等。

#### 3.1 基于特征关联的学习方法

基于特征关联的学习方法主要是利用不同特征之间的关联性和相互作用进行学习和诊断,更多的在于探索正常状态与故障状态特征之间的关联关系,以提高故障诊断的准确率。

灰色理论<sup>[26]</sup>通过研究设备运行状态与故障状态特征的相关性来预测含有故障状态的特性和趋势<sup>[27]</sup>。Wang 等人<sup>[28]</sup>使用灰色预测模型对燃料电池的运行特征进行预测,利用特征的预测值来判断未来的运行状态,从而实现故障诊断。Hu 等人<sup>[26]</sup>提出基于灰色理论和专家系统的轨道电路故障预测方法。为了更有效的利用基于灰色理论所学习到的特征之间的关联性,Dong 等人<sup>[29]</sup>提出一种粗糙集与灰色关联分析相结合的冗余保护配置变电站故障诊断方法,Wu 等人<sup>[30]</sup>提出基于灰色理论的自适应动态阈值调整算法。

多元统计分析法主要有主成分分析法(Principal Component Analysis, PCA)、独立元分析法(Independent Components Analysis, ICA)、偏最小二乘法(Partial Least Squares, PLS)和非负矩阵分解(Nonnegative Matrix Factorization, NMF)等方法。主成分分析法是通过降维处理,提取数据特征,消除不同指标间的相关性。Du 等人<sup>[36]</sup>集成经验模式分解、主成分分析法、累积和等方法用于故障诊断。主成分分析法需要假设数据服从高斯分布,而工业数据未必完全服从高斯分布。独立元分析法假设非高斯源信号的相互独立性,将信号或数据分离为相互独立的变量<sup>[37]</sup>。例如,Xiong 等人<sup>[38]</sup>采用独立元分析法寻找电站故障的特征振动信号;Ali 等人<sup>[39]</sup>利用独立元分析法区分发电厂冷凝器系统中多个不同部分的主要异常因素;Yu 等人<sup>[40]</sup>在机器故障先验知识的基础上结合独立元分析法提取故障特征。偏最小二乘法是一种多元统计分析方法,适用于变量间的多重相关性建模。Jiao 等人<sup>[41]</sup>将偏最小二乘法用于非线性质量相关故障检测,提出核偏最小二乘(Kernel Partial Least Squares, KPLS)模型。Zhu 等人<sup>[42]</sup>利用

偏最小二乘法处理非平稳、非线性的变压器放电信号,提取特征之间的相互关系。偏最小二乘法算法可以实现多变量间的回归建模,且能够处理自变量间的多重相关性,但工业数据内部往往存在错综复杂的动态关系,偏最小二乘法难以发挥有效作用。非负矩阵分解是一种矩阵分解方法,在一定程度上可以降低非线性的工业系统数据的维度<sup>[43]</sup>,例如,感应电机故障诊断系统<sup>[44]</sup>、轴承故障诊断系统<sup>[45]</sup>。在非负矩阵分解的优化和改进方面,Chen 等人<sup>[46]</sup>提出了有监督的非负矩阵分解方法分离特征以缓解非负矩阵分解缺乏先验知识不足的问题。Yang 等人<sup>[47]</sup>将类别信息引入到非负矩阵分解中以解决在有类标签数据的监督任务中表现不佳的难题。非负矩阵分解算法计算效率高,大规模数据处理速度快,但是非负矩阵分解不允许矩阵中出现负值,且无法处理数据间复杂的因果关系。

### 3.2 基于特征工程的学习方法

在数据驱动与领域经验结合的阶段,决策树、支持向量机和贝叶斯网络等方法主要是依赖特征工程以提取与工业故障相关的特征信息,进而为故障诊断提供依据。

决策树<sup>[48]</sup>算法适用于多故障诊断领域,且更容易解释,例如,轴承故障诊断<sup>[49]</sup>、离心泵故障诊断<sup>[50]</sup>、铣刀状态监测<sup>[51]</sup>、风力涡轮机故障诊断<sup>[52]</sup>、光伏系统<sup>[53]</sup>。在其他领域中,一些学者将决策树与其他算法进行了结合。例如,Aydin 等人<sup>[54]</sup>基于边界分析法和模糊决策树算法提出了新的感应电机故障诊断方案;Li 等人<sup>[55]</sup>提出了将决策树模型与基于虚拟传感器的故障指示器(fault indicators, FI)相结合的“三阶段法”进行故障诊断与追溯。决策树算法可以在没有假设的情况下对系统进行操作,不依赖于专家解释,能够完成缺失数据的诊断任务,模型易于实现,但是泛化能力较低,容易过拟合,进而降低故障诊断与追溯的性能。

支持向量机是基于结构风险最小化原理的有监督机器学习算法<sup>[56]</sup>。Wu 等人<sup>[57]</sup>通过多尺度置换熵从故障轴承振动信号中提取特征,然后应用支持向量机实现故障诊断。Saidi 等人<sup>[58]</sup>采用主成分分析法对轴承振动信号进行降维处理,然后采用支持向量机进行故障隔离与诊断。Jegadeeshwaran 等人<sup>[59]</sup>将决策树与支持向量机进行结合,分别应用于液压制动器信号的特征工程和故障诊断。由于支持向量机算法在二次规划问题中实时性较差,不适合在线故障诊断,对此,Deng 等人<sup>[60]</sup>提出一种将支持向量机和纠错输出码相结合的方法,提升了传感器故障特征提取和在线识别能力。支持向量机诊断模型对内核参数敏感,不合适的内核参数会影响诊断结果,同时处理多故障诊断任务也存在一定的困难。

贝叶斯网络是一种重要的概率图模型,可以有效地处理不确定知识表达和推理等问题<sup>[61]</sup>。例如,Amin 等人<sup>[62]</sup>提出基于动态贝叶斯网络的故障诊断方案;Liu 等人<sup>[63]</sup>采用动态贝叶斯网络进行海底生产系统的故障诊断。为了提高基于贝叶斯网络的故障诊断模型的准确度

和灵敏度, Yu 等人<sup>[64]</sup>采用改进的独立元分析法算法识别故障过程变量, 再根据过程变量及其流程图获得的依赖关系建立贝叶斯网络模型; Cai 等人<sup>[65]</sup>和 Don 等人<sup>[66]</sup>将隐马尔可夫与动态贝叶斯网络相结合, 隐马尔可夫用于过程历史数据异常检测, 贝叶斯网络用于故障原因诊断; 以及 Amin 等人<sup>[67]</sup>将主成分分析法与贝叶斯网络相结合。贝叶斯网络算法可以在数据不完备的情况下进行故障诊断与追溯, 但是对于复杂系统故障诊断较为困难。

伴随着数字化技术的发展, 越来越多的工业故障数据被收集和存储, 这为数据主导的故障诊断方法提供了支撑, 决策树、支持向量机和贝叶斯网络等机器学习算法的应用也逐步从数据驱动与领域经验结合的阶段, 过渡到以数据主导和可解释性结合的阶段, 逐步减少了特征工程的需求和复杂性。

### 3.3 基于时序特征的时序分析方法

上述基于特征工程的方法没有考虑数据在时间上的影响, 而大多工业数据都具有时序特征, 因而在处理数据时往往会忽视数据在时间上的相关性。对此, 时序分析方法被用于故障诊断以利用时序特征。

互相关分析(Cross-Correlation Analysis, CCA)是一种用于衡量两个相关信号之间相似性强度的算法, 其通过分析时间序列间的关联信息来推断因果关系。目前, 已有多个领域的故障诊断算法采用互相关分析算法, 例如, 监测可变负载和变速齿轮箱状态<sup>[67]</sup>、输电线路故障诊断<sup>[68]</sup>、识别变压器故障<sup>[69]</sup>等。格兰杰因果分析(Granger Causality, GC)通过对工业过程参数进行分析, 明确过程参数之间变化的因果关系, 构建相应的因果拓扑图<sup>[70]</sup>。在工业故障诊断领域, 已有学者将格兰杰因果分析用于解决过程变量之间相互扰动、确定变量间关系的工作中<sup>[70][71][31]</sup>。互相关分析法算法易于建模和自动化, 同时对因果图的解释简单, 诊断效率高, 但是它难以区分出复杂工业系统中时间序列之间的直接或间接因果关系。格兰杰因果分析算法对数据选择具有鲁棒性, 计算负荷较低, 且得到了很好的工业应用。

在数字驱动与领域经验结合的阶段中, 这些数字化方法对于人工经验依赖程度较小, 可以在缺乏先验知识的情况下进行故障诊断, 有助于在不同的领域进行数据驱动的研究和分析。然而, 这些数字化方法在故障诊断过程中面临较高的复杂性和繁琐性, 同时在特征工程方面仍然存在一定的挑战性, 特征工程可以显著影响分析结果的准确性和可解释性。

## 4 第三阶段: 数据驱动主导与可解释性结合的数字化方法

随着数字化技术的发展, 知识图谱、图神经网络、深度学习等方法的出现减少了特征工程的需求和复杂性, 提升了故障诊断算法的学习能力和准确率。在数据驱动主导与可解释性

结合阶段，故障诊断数字化技术是通过学习工业系统在正常和异常工况下的历史数据特征，同时根据学习到的特征识别机器状态，进而达到故障诊断以及原因追溯的目的。

4.1 基于浅层神经网络的故障诊断方法

反向传播网络(Back Propagation Neural Network, BPNN)作为一种自适应模式的浅层神经网络，具有良好的适应性和学习能力<sup>[72]</sup>，其网络拓扑结构如图 2 所示。Zhao 等人<sup>[73]</sup>利用二次函数对轨道电路数据特征进行提取，并训练一个反向传播神经网络，进行调谐单元的故障诊断。Ngaopitakkul 等人<sup>[74]</sup>采用离散小波变换分解信号高频分量，构建基于反向传播网络的决策算法。Zhang 等人<sup>[75]</sup>基于改进的时间同步平均算法提取齿轮状态特征，然后训练反向传播网络来识别齿轮芯片级别。在算法优化方面，Yu 等人<sup>[76]</sup>利用自适应遗传算法优化反向传播网络，实现液体火箭发动机的实时故障检测。反向传播网络算法能够从工业数据中学习诊断知识，识别出机器多种状态，但是基于反向传播网络的诊断算法复杂度大大增加，存在过拟合的困境，可解释性较差。




图 2 基于反向传播网络<sup>[77]</sup>的故障诊断示意图

4.2 基于深度学习的故障诊断方法

深度学习的方法包括深度置信网络 (Deep Belief Network, DBN)、卷积神经网络 (Convolutional Neural Network, CNN)、循环神经网络 (Recurrent Neural Network, RNN) 以及图神经网络等。深度置信网络是一种具有许多神经元隐藏层的生成模型，由多个受限玻尔兹曼机 (Restricted Boltzmann Machine, RBM) 堆叠而成<sup>[78]</sup>，其结构如图 3 所示。其特点有以下两个方面，其一，由于它特殊的结构能够自适应地提取复杂特征，其二，深度置信网络在处理高维和非线性数据方面具有优势<sup>[79]</sup>。Zhao 等人<sup>[79]</sup>提出一种基于深度置信网络的模拟电路故障诊断方法，简化了诊断设计；Zhang 等人<sup>[80]</sup>设计一种基于深度置信网络的在线电缆故障识别算法，相较于传统浅层神经网络，该算法在准确性方面有了一定提升。由于不同领域的特殊性，一些学者针对不同领域的故障诊断算法进行相应的改进，例如，Shao 等人<sup>[81]</sup>针对滚动轴承故障识别开发了一种基于自适应深度置信网络的故障诊断方法；Zhang 等人<sup>[82]</sup>提出了一



种基于可扩展深度置信网络的化学过程故障诊断模型。深度置信网络适用于处理高维和非线性数据，能够表征系统数据与故障特征之间的映射关系，但是该诊断模型结构较为复杂，难以训练，收敛速度慢。

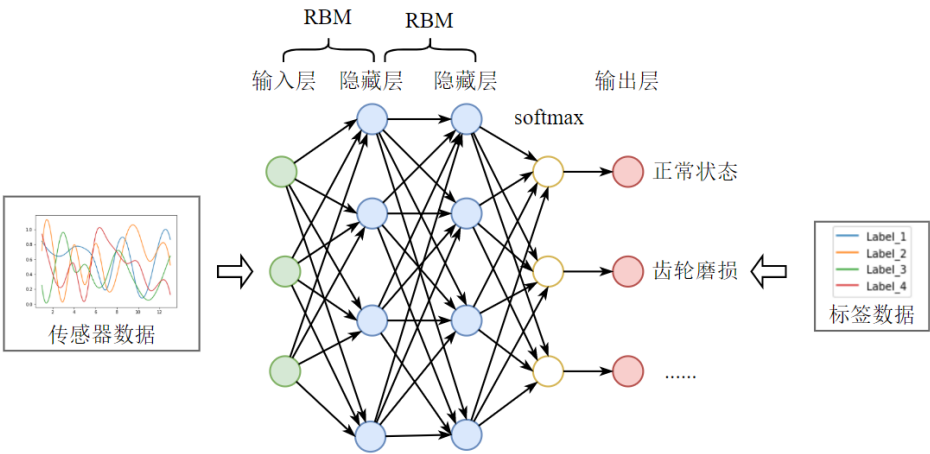


图 3 基于深度置信网络<sup>[83]</sup>的故障诊断示意图

卷积神经网络是一种前馈神经网络，在故障诊断领域，因其具有强的局部特征提取能力和灵活的结构而得到广泛的使用<sup>[84]</sup>，其结构如图 4 所示。例如，Janssens 等人<sup>[85]</sup>将卷积神经网络应用于轴承故障检测，提出状态监测特征学习模型；Wu 等人<sup>[86]</sup>和 Pan 等人<sup>[87]</sup>分别将深度卷积神经网络应用于化工过程故障诊断和机器人故障诊断；Zhang 等人<sup>[88]</sup>提出基于卷积神经网络的制造系统故障诊断算法，完成特征提取和故障诊断。目前，相关研究关注不同故障率导致的故障类型分布不平衡以及多故障容易与单故障混淆等问题，Chen 等人<sup>[89]</sup>提出基于随机过采样的随机离散时间序列深度卷积神经网络算法，以利用时序特点提高诊断性能。

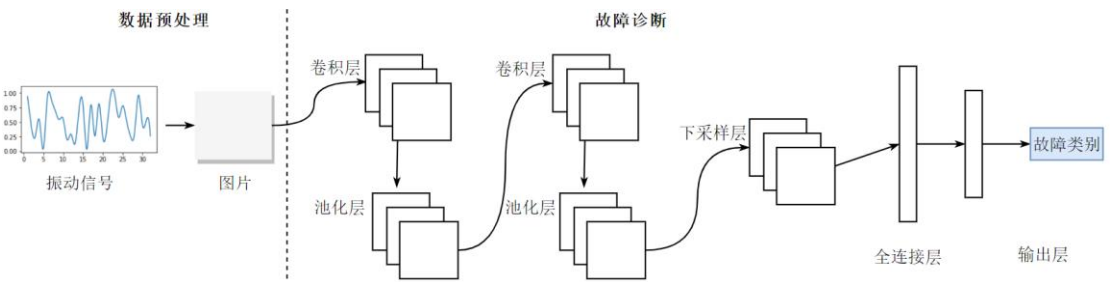


图 4 基于卷积神经网络<sup>[90]</sup>的故障诊断示意图

循环神经网络是一种处理时间序列数据的框架，具有记忆历史信息的能力，适合于动态故障诊断<sup>[91]</sup>，其结构如图 5 所示。由于具有学习长期依赖性的能力，长短期记忆网络 (Long Short-Term Memory, LSTM) 在故障诊断领域受到了关注，例如，Wu 等人<sup>[92]</sup>提出了基于 LSTM 的设备退化序列故障预算法；Lee 等人<sup>[93]</sup>使用基于注意力的 LSTM 算法诊断匝间短路故障；Chadha 等人<sup>[94]</sup>设计基于双向 LSTM 的状态监测和故障诊断的新方法，该方法允许处理更长时间序列内的变量关系；以及 Kang 等人<sup>[95]</sup>使用 LSTM 进行复杂化学过程的早故障

诊断。现有的故障诊断方法大多只关注故障类型的识别，而忽视了设备性能退化的问题，对此，Qin 等人<sup>[96]</sup>提出多重卷积循环神经网络，用于同时诊断故障类型和监测性能退化状态。循环神经网络具有记忆历史信息的能力，能够处理更长时间范围内的故障关系，有利于避免关键过程故障，但是存在梯度消失的问题，且诊断模型较为复杂，难以训练。

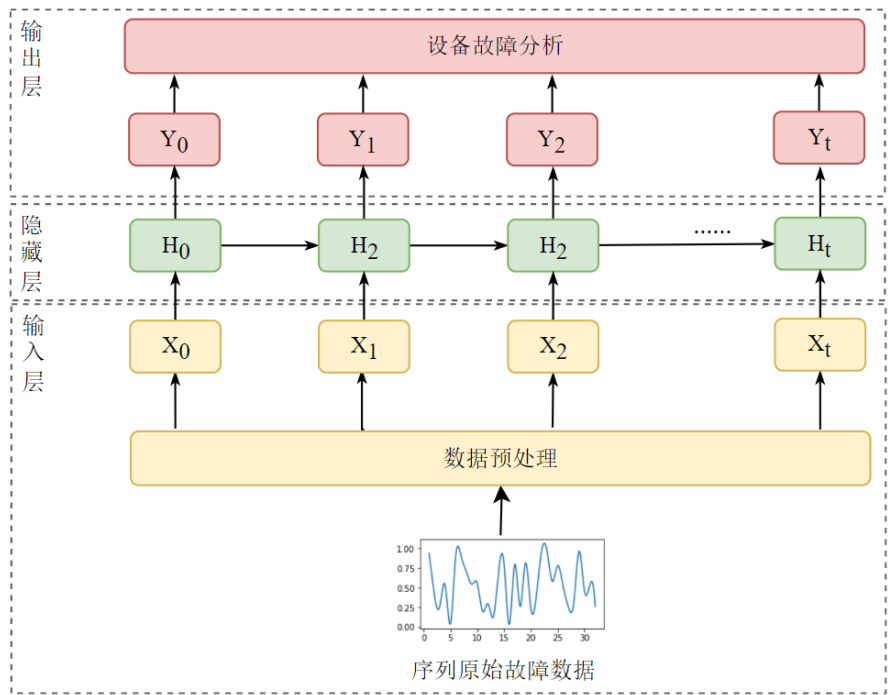


图 5 基于循环神经网络<sup>[97]</sup>的故障诊断示意图

### 4.3 基于图神经网络的故障诊断方法

图神经网络在非欧几里德空间对于图数据具有强大的建模能力，度量未知故障和已知故障之间的相似，其结构如图 6 所示。目前，在故障诊断领域，应用范围最广的 GNN 架构，分别是图卷积神经网络(Graph Convolutional Network, GCN)、图注意力网络(Graph Attention Network, GAN)。GCN 适用于挖掘故障类型与过程变量之间复杂的非线性关系，还能通过邻接矩阵表示未知样本与标记样本之间的相似度<sup>[98]</sup>。例如，Liao 等人<sup>[98]</sup>提出了一种基于 GCN 的变压器故障诊断算法，Zhang 等人<sup>[99]</sup>基于深度 GCN 架构设计了一种基于声学信息的轴承故障诊断，且 Wang 等人<sup>[100]</sup>提出了一种基于振动的 GCN 的轴承故障诊断算法。由于 GCN 也存在着诸多局限性，一些学者针对这些局限性给出了相应的解决方案。例如，Chen 等人<sup>[101]</sup>采用基于结构分析的 GCN 故障诊断模型来解决 GCN 严重依赖于标记数据集这一缺点；Li 等人<sup>[102]</sup>提出用于故障诊断的多感受野 GCN 算法来解决 GCN 感受野固定的局限性。针对小样本机械故障诊断困难的问题，Gao 等人<sup>[103]</sup>构建基于半监督 GCN 的旋转机械故障智能诊断算法。GCN 模型的性能取决于邻接矩阵，为了更好的表示与相邻节点的连接关系，GAN

被提出。GAN 将注意力机制应用于度量不同样本之间的相似度，同时更关注其他样本的特征<sup>[104]</sup>。目前，GAN 已被用于多个故障诊断领域，例如，柴油机工况识别模型<sup>[104]</sup>、轴承故障诊断<sup>[105]</sup>。在实际工业过程中会不断出现新的故障类型，为了使得新的故障类型能够在第一次出现后就能迅速被识别出来，Long 等人<sup>[106]</sup>采用自适应 GAN 实现元学习器，使其具有元知识学习能力。GNN 既可以挖掘出系统状态数据与故障特征之间复杂的非线性关系，还可以度量未知故障与已知故障之间的相似度，但是模型灵活性较差，且有限的感受野限制了在故障数据特征表示方面的有效性。

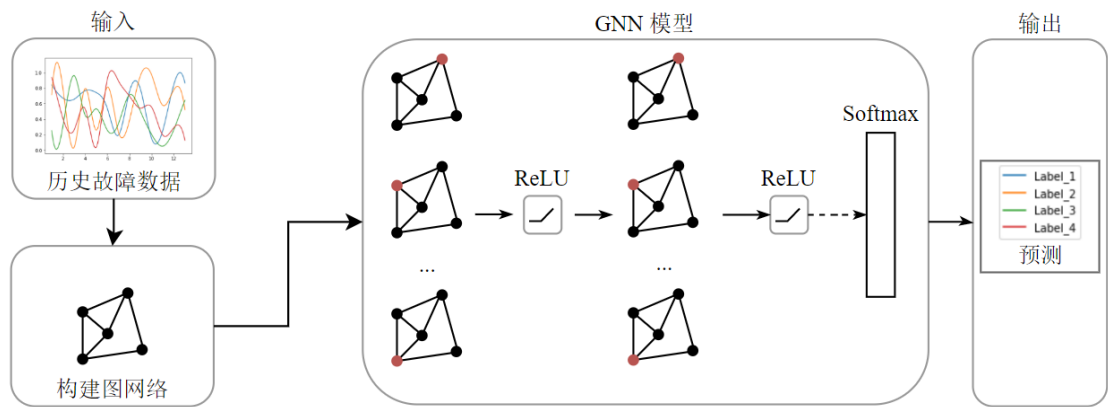


图 6 基于图神经网络<sup>[107]</sup>的故障诊断示意图

在数据驱动主导与可解释性结合的阶段，反向传播算法、深度置信网络、卷积神经网络、循环神经网络相对于强依赖特征工程的机器学习算法，具有良好的适应性和学习能力，能够处理高维、多源的工业数据。然而，这些模型的可解释性相对较差。相比之下，图神经网络在这方面具有显著优势：一方面相较于第一阶段，它建模的图网络是直接从工业数据中学习来的，对专家经验依赖度低；另一方面相较于第二阶段，它具有更好的故障追溯能力，因此更具有可解释性，从而很好的体现出数据驱动和可解释性等特点。

## 5 挑战与讨论

工业系统运行数据具有海量、高维、异构性以及时序性等特点，如何有效的挖掘出数据中潜在的故障因果关系是建立复杂系统模型的关键问题之一。数字化的方法正逐渐减少对领域知识的依赖，并转向以数据为主导，提高了故障诊断的效率和准确率，但是仍然面临数据标注少、追溯难等问题。具体包括：

（1）在实际应用中，一方面存在数据收集困难、标注代价高等问题；另一方面由于现今系统的完备性和抗干扰性强，使得收集到的系统故障样本远远较少，虽然数据量大但有效信息少，这增加了故障诊断与追溯的难度。因此，如何处理好小样本问题是提升诊断模型泛化性和准确率的关键挑战；

(2) 复杂工业系统内部各个组件、各个单元相互制约,呈现出层次性、传播性等特点,使得在一个时间节点上发生的故障很有可能引起后续短时间内其他组件功能异常,甚至是多个故障并发。但是目前的故障诊断与追溯模型大多只关注到单故障诊断问题,多故障诊断问题也是很值得探究的问题;

(3) 图神经网络的发展给可解释性故障诊断和追溯提供了支持,如何将时序和图方法进行结合,既考虑动态性又考虑工业数据之间的关系,成为故障诊断和追溯问题的重点研究方向之一。

## 6 结束语

本文对工业故障诊断数字化方法的国内外研究进展进行了分析,从领域经验主导、数据驱动与领域经验结合、数据驱动主导与可解释性结合三个阶段开展研究,可以看到,数据的积累为诊断提供了更加丰富的数据基础,同时在故障诊断中引入数字化方法有助于提升工业领域关键环节的可靠性和生产效率,这些为工业数字化转型提供了技术和方法的支撑,促进了工业生产的智能化和可持续发展。

## 参考文献:

- [1] 任浩, 屈剑锋, 柴毅, 等. 深度学习在故障诊断领域中的研究现状与挑战[J]. 控制与决策, 2017, 32(8): 1345-1358.
- [2] Gao Z, Cecati C, Ding S X. A survey of fault diagnosis and fault-tolerant techniques—Part I: Fault diagnosis with model-based and signal-based approaches[J]. IEEE transactions on industrial electronics, 2015, 62(6): 3757-3767.
- [3] 周东华, 胡艳艳. 动态系统的故障诊断技术[J]. 自动化学报, 2009, 35(6): 748-758.
- [4] Yang F, Xiao D, Shah S L. Signed directed graph-based hierarchical modelling and fault propagation analysis for large-scale systems[J]. IET Control Theory & Applications, 2013, 7(4): 537-550.
- [5] Yong-kuo L, Abiodun A, Zhi-bin W, et al. A cascade intelligent fault diagnostic technique for nuclear power plants[J]. Journal of Nuclear Science and Technology, 2018, 55(3): 254-266.
- [6] Peng D, Geng Z, Zhu Q. A multilogic probabilistic signed directed graph fault diagnosis approach based on Bayesian inference[J]. Industrial & Engineering Chemistry Research, 2014, 53(23): 9792-9804.
- [7] Liu Y K, Wu G H, Xie C L, et al. A fault diagnosis method based on signed directed graph and

- matrix for nuclear power plants[J]. *Nuclear Engineering and Design*, 2016, 297: 166-174.
- [8] Gang X, Jing L, Zehua C. Hierarchy fault diagnosis based on signed directed graphs model[C]//2012 24th Chinese Control and Decision Conference (CCDC). IEEE, 2012: 2270-2274.
- [9] 马亮,彭开香,董洁.工业过程故障根源诊断与传播路径识别技术综述[J/OL]. *自动化学报*:1-15[2022-06-06].<http://kns.cnki.net/kcms/detail/11.2109.TP.20200904.1543.003.html>.
- [10] Chen Y, Zhen Z, Yu H, et al. Application of fault tree analysis and fuzzy neural networks to fault diagnosis in the internet of things (IoT) for aquaculture[J]. *Sensors*, 2017, 17(1): 153.
- [11] Wang L, Li S, Wei O, et al. An automated fault tree generation approach with fault configuration based on model checking[J]. *IEEE Access*, 2018, 6: 46900-46914.
- [12] Duan R, Zhou H. A new fault diagnosis method based on fault tree and Bayesian networks[J]. *Energy Procedia*, 2012, 17: 1376-1382.
- [13] Zheng Y, Zhao F, Wang Z. Fault diagnosis system of bridge crane equipment based on fault tree and Bayesian network[J]. *The International Journal of Advanced Manufacturing Technology*, 2019, 105(9): 3605-3618.
- [14] Duan R, Fan J. Reliability evaluation of data communication system based on dynamic fault tree under epistemic uncertainty[J]. *Mathematical Problems in Engineering*, 2014, 2014.
- [15] Basile F. Overview of fault diagnosis methods based on Petri net models[C]//2014 European Control Conference (ECC). IEEE, 2014: 2636-2642.
- [16] Mansour M M, Wahab M A A, Soliman W M. Petri nets for fault diagnosis of large power generation station[J]. *Ain Shams Engineering Journal*, 2013, 4(4): 831-842.
- [17] Al-Ajeli A, Parker D. Fault diagnosis in labelled Petri nets: A Fourier–Motzkin based approach[J]. *Automatica*, 2021, 132: 109831.
- [18] Liu H C, Lin Q L, Ren M L. Fault diagnosis and cause analysis using fuzzy evidential reasoning approach and dynamic adaptive fuzzy Petri nets[J]. *Computers & Industrial Engineering*, 2013, 66(4): 899-908.
- [19] Zhang Y, Zhang Y, Wen F, et al. A fuzzy Petri net based approach for fault diagnosis in power systems considering temporal constraints[J]. *International Journal of Electrical Power & Energy Systems*, 2016, 78: 215-224.
- [20] Benmoussa S, Bouamama B O, Merzouki R. Bond graph approach for plant fault detection and

- isolation: Application to intelligent autonomous vehicle[J]. IEEE Transactions on Automation Science and Engineering, 2013, 11(2): 585-593.
- [21] Badoud A E, Khemliche M, Ould Bouamama B, et al. Bond graph algorithms for fault detection and isolation in wind energy conversion[J]. Arabian Journal for Science and Engineering, 2014, 39(5): 4057-4076.
- [22] Chatti N, Ould-Bouamama B, Gehin A L, et al. Signed bond graph for multiple faults diagnosis[J]. Engineering Applications of Artificial Intelligence, 2014, 36: 134-147.
- [23] He J, Zhao H. Fault diagnosis and location based on graph neural network in telecom networks[C]//2020 International Conference on Networking and Network Applications (NaNA). IEEE, 2020: 304-309.
- [24] Zhang Y J, Hu L S. Fault propagation inference based on a graph neural network for steam turbine systems[J]. Energies, 2021, 14(2): 309.
- [25] Li T, Zhou Z, Li S, et al. The emerging graph neural networks for intelligent fault diagnostics and prognostics: A guideline and a benchmark study[J]. Mechanical Systems and Signal Processing, 2022, 168: 108653.
- [26] Hu L Q, He C F, Cai Z Q, et al. Track circuit fault prediction method based on grey theory and expert system[J]. Journal of Visual Communication and Image Representation, 2019, 58: 37-45.
- [27] 文成林, 吕菲亚, 包哲静, 等. 基于数据驱动的微小故障诊断方法综述[J]. 自动化学报, 2016, 42(9): 1285-1299.
- [28] Wang M H, Tsai H H. Fuel cell fault forecasting system using grey and extension theories[J]. IET Renewable Power Generation, 2012, 6(6): 373-380.
- [29] Dong H, Li X, Wei Z. Substation fault diagnosis based on rough sets and grey relational analysis[J]. TELKOMNIKA Indonesian Journal of Electrical Engineering, 2014, 12(2): 1162-1168.
- [30] Wu L, Yao B, Peng Z, et al. An adaptive threshold algorithm for sensor fault based on the grey theory[J]. Advances in Mechanical Engineering, 2017, 9(2): 1687814017693193.
- [31] Pyun H, Kim K, Ha D, et al. Root causality analysis at early abnormal stage using principal component analysis and multivariate Granger causality[J]. Process Safety and Environmental Protection, 2020, 135: 113-125.

- [32] Shi S, Li G, Chen H, et al. An efficient VRF system fault diagnosis strategy for refrigerant charge amount based on PCA and dual neural network model[J]. *Applied Thermal Engineering*, 2018, 129: 1252-1262.
- [33] Zhu J, Hu T, Jiang B, et al. Intelligent bearing fault diagnosis using PCA–DBN framework[J]. *Neural Computing and Applications*, 2020, 32(14): 10773-10781.
- [34] Zhang K, Su J, Sun S, et al. Compressor fault diagnosis system based on PCA-PSO-LSSVM algorithm[J]. *Science progress*, 2021, 104(3): 00368504211026110.
- [35] Jiang Q, Yan X, Li J. PCA-ICA integrated with Bayesian method for non-Gaussian fault diagnosis[J]. *Industrial & Engineering Chemistry Research*, 2016, 55(17): 4979-4986.
- [36] Du Y, Du D. Fault detection and diagnosis using empirical mode decomposition based principal component analysis[J]. *Computers & Chemical Engineering*, 2018, 115: 1-21.
- [37] Ajami A, Daneshvar M. Data driven approach for fault detection and diagnosis of turbine in thermal power plant using Independent Component Analysis (ICA)[J]. *International Journal of Electrical Power & Energy Systems*, 2012, 43(1): 728-735.
- [38] Xiong T, Sheng C, Duan Z, et al. Fusing of multi-channel sensors for power station fault diagnosis in marine power systems[J]. *Elektronika ir Elektrotechnika*, 2013, 19(5): 53-56.
- [39] Ali A, Mahdi D. Independent component analysis approach for fault diagnosis of condenser system in thermal power plant[J]. *Journal of Central South University*, 2014, 21(1): 242-251.
- [40] Yu G. Fault feature extraction using independent component analysis with reference and its application on fault diagnosis of rotating machinery[J]. *Neural computing and applications*, 2015, 26(1): 187-198.
- [41] Jiao J, Zhao N, Wang G, et al. A nonlinear quality-related fault detection approach based on modified kernel partial least squares[J]. *ISA transactions*, 2017, 66: 275-283.
- [42] Zhu Y, Jia Y, Wang L. Partial discharge pattern recognition method based on variable predictive model-based class discriminate and partial least squares regression[J]. *IET Science, Measurement & Technology*, 2016, 10(7): 737-744.
- [43] Chen Y, Li M, Liang L, et al. Feature extraction for fault diagnosis utilizing supervised nonnegative matrix factorization combined statistical model[C]//2016 9th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI). IEEE, 2016: 1188-1193.

- [44] Jiang S B, Wong P K, Guan R, et al. An efficient fault diagnostic method for three-phase induction motors based on incremental broad learning and non-negative matrix factorization[J]. IEEE Access, 2019, 7: 17780-17790.
- [45] Hao Y, Song L, Wang M, et al. Underdetermined source separation of bearing faults based on optimized intrinsic characteristic-scale decomposition and local non-negative matrix factorization[J]. IEEE Access, 2019, 7: 11427-11435.
- [46] Chen Y, Li M, Liang L, et al. Feature extraction for fault diagnosis utilizing supervised nonnegative matrix factorization combined statistical model[C]//2016 9th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI). IEEE, 2016: 1188-1193.
- [47] Yang Y, Ming A, Zhang Y, et al. Discriminative non-negative matrix factorization (DNMF) and its application to the fault diagnosis of diesel engine[J]. Mechanical Systems and Signal Processing, 2017, 95: 158-171.
- [48] Abdallah I, Dertimanis V, Mylonas H, et al. Fault diagnosis of wind turbine structures using decision tree learning algorithms with big data[M]//Safety and Reliability–Safe Societies in a Changing World. CRC Press, 2018: 3053-3061.
- [49] Amarnath M, Sugumaran V, Kumar H. Exploiting sound signals for fault diagnosis of bearings using decision tree[J]. Measurement, 2013, 46(3): 1250-1256.
- [50] Muralidharan V, Sugumaran V. Feature extraction using wavelets and classification through decision tree algorithm for fault diagnosis of mono-block centrifugal pump[J]. Measurement, 2013, 46(1): 353-359.
- [51] Madhusudana C K, Kumar H, Narendranath S. Fault diagnosis of face milling tool using decision tree and sound signal[J]. Materials Today: Proceedings, 2018, 5(5): 12035-12044.
- [52] Abdallah I, Dertimanis V, Mylonas H, et al. Fault diagnosis of wind turbine structures using decision tree learning algorithms with big data[M]//Safety and Reliability–Safe Societies in a Changing World. CRC Press, 2018: 3053-3061.
- [53] Benkercha R, Moulahoum S. Fault detection and diagnosis based on C4. 5 decision tree algorithm for grid connected PV system[J]. Solar Energy, 2018, 173: 610-634.
- [54] Aydin I, Karakose M, Akin E. An approach for automated fault diagnosis based on a fuzzy decision tree and boundary analysis of a reconstructed phase space[J]. ISA transactions, 2014,



53(2): 220-229.

- [55] Li G, Chen H, Hu Y, et al. An improved decision tree-based fault diagnosis method for practical variable refrigerant flow system using virtual sensor-based fault indicators[J]. Applied Thermal Engineering, 2018, 129: 1292-1303.
- [56] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.
- [57] Wu S D, Wu P H, Wu C W, et al. Bearing fault diagnosis based on multiscale permutation entropy and support vector machine[J]. Entropy, 2012, 14(8): 1343-1356.
- [58] Saidi L, Ali J B, Fnaiech F. Application of higher order spectral features and support vector machines for bearing faults classification[J]. ISA transactions, 2015, 54: 193-206.
- [59] Jegadeeshwaran R, Sugumaran V. Fault diagnosis of automobile hydraulic brake system using statistical features and support vector machines[J]. Mechanical Systems and Signal Processing, 2015, 52: 436-446.
- [60] Deng F, Guo S, Zhou R, et al. Sensor multifault diagnosis with improved support vector machines[J]. IEEE transactions on automation science and engineering, 2015, 14(2): 1053-1063.
- [61] Cai B, Huang L, Xie M. Bayesian networks in fault diagnosis[J]. IEEE Transactions on industrial informatics, 2017, 13(5): 2227-2240.
- [62] Amin M T, Khan F, Imtiaz S. Fault detection and pathway analysis using a dynamic Bayesian network[J]. Chemical Engineering Science, 2019, 195: 777-790.
- [63] Liu P, Liu Y, Cai B, et al. A dynamic Bayesian network based methodology for fault diagnosis of subsea Christmas tree[J]. Applied Ocean Research, 2020, 94: 101990.
- [64] Yu H, Khan F, Garaniya V. Modified independent component analysis and Bayesian network-based two-stage fault diagnosis of process operations[J]. Industrial & Engineering Chemistry Research, 2015, 54(10): 2724-2742.
- [65] Cai B, Liu Y, Xie M. A dynamic-Bayesian-network-based fault diagnosis methodology considering transient and intermittent faults[J]. IEEE Transactions on Automation Science and Engineering, 2016, 14(1): 276-285.
- [66] Don M G, Khan F. Dynamic process fault detection and diagnosis based on a combined approach of hidden Markov and Bayesian network model[J]. Chemical Engineering Science, 2019, 201: 82-96.

- [67] Amin M T, Khan F, Ahmed S, et al. A data-driven Bayesian network learning method for process fault diagnosis[J]. *Process Safety and Environmental Protection*, 2021, 150: 110-122.
- McBain J, Timusk M. Cross Correlation for Condition Monitoring of Variable Load and Speed Gearboxes[J]. *Journal of Industrial Mathematics*, 2014, 2014.
- [68] Dasgupta A, Debnath S, Das A. Transmission line fault detection and classification using cross-correlation and k-nearest neighbor[J]. *International Journal of Knowledge-based and Intelligent Engineering Systems*, 2015, 19(3): 183-189.
- [69] Saleh S M, EL-Hoshy S H, Gouda O E. Proposed diagnostic methodology using the cross-correlation coefficient factor technique for power transformer fault identification[J]. *IET Electric Power Applications*, 2017, 11(3): 412-422.
- [70] Zuqui Jr G C, Munaro C J. Fault detection and isolation via Granger causality[J]. *Proceedings of the Anais do XII Simpósio Brasileiro de Automação Inteligente (XII SBAI)*, Natal, Brazil, 2015: 25-28.
- [71] Ahmed U, Ha D, Shin S, et al. Estimation of disturbance propagation path using principal component analysis (PCA) and multivariate granger causality (MVGC) techniques[J]. *Industrial & Engineering Chemistry Research*, 2017, 56(25): 7260-7272.
- [72] Dong S, Xu X, Liu J, et al. Rotating machine fault diagnosis based on locality preserving projection and back propagation neural network–support vector machine model[J]. *Measurement and Control*, 2015, 48(7): 211-216.
- [73] Zhao L H, Zhang C L, Qiu K M, et al. A fault diagnosis method for the tuning area of jointless track circuits based on a neural network[J]. *Proceedings of the Institution of Mechanical Engineers, Part F: Journal of rail and rapid transit*, 2013, 227(4): 333-343.
- [74] Ngaopitakkul A, Bunjongjit S. An application of a discrete wavelet transform and a back-propagation neural network algorithm for fault diagnosis on single-circuit transmission line[J]. *International Journal of Systems Science*, 2013, 44(9): 1745-1761.
- [75] Zhang X, Xiao L, Kang J. Application of an improved Levenberg-Marquardt back propagation neural network to gear fault level identification[J]. *Journal of Vibroengineering*, 2014, 16(2): 855-868.
- [76] Yu H, Wang T. A Method for Real-Time Fault Detection of Liquid Rocket Engine Based on Adaptive Genetic Algorithm Optimizing Back Propagation Neural Network[J]. *Sensors*, 2021,

21(15): 5026.

- [77] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. *nature*, 1986, 323(6088): 533-536.
- [78] Zhang Z, Zhao J. A deep belief network based fault diagnosis model for complex chemical processes[J]. *Computers & chemical engineering*, 2017, 107: 395-407.
- [79] Zhao G, Liu X, Zhang B, et al. A novel approach for analog circuit fault diagnosis based on deep belief network[J]. *Measurement*, 2018, 121: 170-178.
- [80] Zhang Y, Mei W, Dong G, et al. A cable fault recognition method based on a deep belief network[J]. *Computers & Electrical Engineering*, 2018, 71: 452-464.
- [81] Shao H, Jiang H, Wang F, et al. Rolling bearing fault diagnosis using adaptive deep belief network with dual-tree complex wavelet packet[J]. *ISA transactions*, 2017, 69: 187-201.
- [82] Zhang Z, Zhao J. A deep belief network based fault diagnosis model for complex chemical processes[J]. *Computers & chemical engineering*, 2017, 107: 395-407.
- [83] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. *Neural computation*, 2006, 18(7): 1527-1554.
- [84] Chen Z, Mauricio A, Li W, et al. A deep learning method for bearing fault diagnosis based on cyclic spectral coherence and convolutional neural networks[J]. *Mechanical Systems and Signal Processing*, 2020, 140: 106683.
- [85] Janssens O, Slavkovikj V, Vervisch B, et al. Convolutional neural network based fault detection for rotating machinery[J]. *Journal of Sound and Vibration*, 2016, 377: 331-345.
- [86] Wu H, Zhao J. Deep convolutional neural network model based chemical process fault diagnosis[J]. *Computers & chemical engineering*, 2018, 115: 185-197.
- [87] Pan J, Qu L, Peng K. Sensor and Actuator Fault Diagnosis for Robot Joint Based on Deep CNN[J]. *Entropy*, 2021, 23(6): 751.
- [88] Zhang J, Yi S, Liang G U O, et al. A new bearing fault diagnosis method based on modified convolutional neural networks[J]. *Chinese Journal of Aeronautics*, 2020, 33(2): 439-447.
- [89] Chen S, Ge H, Li J, et al. Progressive improved convolutional neural network for avionics fault diagnosis[J]. *IEEE Access*, 2019, 7: 177362-177375.
- [90] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.

- [91] Liu W, Guo P, Ye L. A low-delay lightweight recurrent neural network (LLRNN) for rotating machinery fault diagnosis[J]. *Sensors*, 2019, 19(14): 3109.
- [92] Wu Q, Ding K, Huang B. Approach for fault prognosis using recurrent neural network[J]. *Journal of Intelligent Manufacturing*, 2020, 31(7): 1621-1633.
- [93] Lee H, Jeong H, Koo G, et al. Attention recurrent neural network-based severity estimation method for interturn short-circuit fault in permanent magnet synchronous machines[J]. *IEEE Transactions on Industrial Electronics*, 2020, 68(4): 3445-3453.
- [94] Chadha G S, Panambilly A, Schwung A, et al. Bidirectional deep recurrent neural networks for process fault classification[J]. *ISA transactions*, 2020, 106: 330-342.
- [95] Kang J L. Visualization analysis for fault diagnosis in chemical processes using recurrent neural networks[J]. *Journal of the Taiwan Institute of Chemical Engineers*, 2020, 112: 137-151.
- [96] Qin N, Liang K, Huang D, et al. Multiple convolutional recurrent neural networks for fault identification and performance degradation evaluation of high-speed train bogie[J]. *IEEE transactions on neural networks and learning systems*, 2020, 31(12): 5363-5376.
- [97] Hochreiter S, Schmidhuber J. Long short-term memory[J]. *Neural computation*, 1997, 9(8): 1735-1780.
- [98] Liao W, Yang D, Wang Y, et al. Fault diagnosis of power transformers using graph convolutional network[J]. *CSEE Journal of Power and Energy Systems*, 2020, 7(2): 241-249.
- [99] Zhang D, Stewart E, Entezami M, et al. Intelligent acoustic-based fault diagnosis of roller bearings using a deep graph convolutional network[J]. *Measurement*, 2020, 156: 107585.
- [100] Wang S H, Xing S B, Lei Y G, et al. Vibration indicator-based graph convolutional network for semi-supervised bearing fault diagnosis[C]//*IOP Conference Series: Materials Science and Engineering*. IOP Publishing, 2021, 1043(5): 052026.
- [101] Chen Z, Xu J, Peng T, et al. Graph convolutional network-based method for fault diagnosis using a hybrid of measurement and prior knowledge[J]. *IEEE transactions on cybernetics*, 2021.
- [102] Li T, Zhao Z, Sun C, et al. Multireceptive field graph convolutional networks for machine fault diagnosis[J]. *IEEE Transactions on Industrial Electronics*, 2020, 68(12): 12739-12749.
- [103] Gao Y, Chen M, Yu D. Semi-supervised graph convolutional network and its application in intelligent fault diagnosis of rotating machinery[J]. *Measurement*, 2021, 186: 110084.

- [104] Huang A, Bao B, Zhao N, et al. Decoupling Identification Method of Continuous Working Conditions of Diesel Engines Based on a Graph Self-Attention Network[J]. IEEE Access, 2022, 10: 36649-36661.
- [105] Jiang L, Li X, Wu L, et al. Bearing fault diagnosis method based on a multi-head graph attention network[J]. Measurement Science and Technology, 2022, 33(7): 075012.
- [106] Long J, Zhang R, Yang Z, et al. Self-Adaptation Graph Attention Network via Meta-Learning for Machinery Fault Diagnosis with Few Labeled Data[J]. IEEE Transactions on Instrumentation and Measurement, 2022.
- [107] Bruna J, Zaremba W, Szlam A, et al. Spectral networks and locally connected networks on graphs[J]. arXiv preprint arXiv:1312.6203, 2013.

#### [作者简介]



杨彪 (1999- ), 男, 硕士, 复旦大学计算机科学技术学院, 主要研究方向为图神经网络、数据科学。



傅玲, (1981- ), 女, 博士, 西门子中国研究院首席专家, 数字孪生方向。



徐蔚峰, (1988- ), 男, 硕士, 西门子中国研究院, 数字孪生方向。



李婧, (1983- ), 女, 博士, 西门子中国研究院 数字孪生与仿真方向研  
发总监。



熊贇, (1980- ), 女, 博士, 复旦大学教授, 上海市数据科学重点实  
验室副主任, 主要研究方向为大数据、数据科学。