

DOI:10.13296/j.1001-1609.hva.2019.12.028

基于时间序列模型的变压器油中溶解气体预测

刘慧鑫¹, 张江龙², 连鸿松¹, 郑东升¹, 赖永华¹

(1. 国网福建省电力有限公司电力科学研究院, 福州 350007; 2. 国网福建省电力有限公司信息通信分公司, 福州 350003))

摘要: 变压器作为电力系统的核心设备,其安全运行是电力系统稳定可靠的基础。根据在线监测系统提供的油中溶解气体含量历史数据,预测未来气体体积分数及其发展趋势,是DGA故障预测的关键,也是在线监测的必要补充和提前预警变压器故障的重要手段。现有的预测算法存在着模型泛化性差和没有考虑时间序列模型等问题。为提高预测能力,文中首先介绍了非时序有监督学习和时间序列模型关键技术及其在变压器油中溶解气体体积分数预测的应用;然后搜集和发布了一个大规模数据样本,为算法提供了一个较为全面的验证集,提高模型的泛化性;最后使用前向数据分割方法进行数据增强,增加模型的训练数据。大量实验证明了时间序列模型在变压器油中溶解气体体积分数预测的有效性。

关键词: 变压器; 油中溶解气体; 预测; 非时序有监督学习; 时间序列学习

Prediction of the Gases Dissolved in Transformer Oil by Sequential Learning

LIU Huixin¹, ZHANG Jianglong², LIAN Hongsong¹, ZHENG Dongsheng¹, LAI Yonghua¹

(1. Electric Power Research Institute, SGCC, Fuzhou 350007, China; 2. Information & Telecommunication Company, SGCC, Fuzhou 350003, China)

Abstract: Transformer is the core equipment in power system and its safe operation is the foundation of the stability and reliability of power system. Prediction of gas contents and the development tendency based on on-line monitoring historical data is the key to DGA failure prediction the necessary supplement to on-line monitoring and an important means of failure prediction of transformers. The existing algorithms have two major drawbacks: ①the datasets are too small to train and validate the proposed models; ②most previous methods make an assumption of that samples from one transformer are independently and identically distributed while paying less attention to the time correlation between samples. To increase predictive ability this paper studied the supervised learning and sequential learning methods and their applications in data prediction of gas dissolved in transformer oil. Then a large-scale dataset was built and released to provide a comprehensive validation set and increase the generalization. Lastly a walk-forward split method was adopted to augment the data. Extensive experiments conducted on a large-scale dataset have well validated the competitiveness of sequential learning on data prediction of gas dissolved in transformer oil.

Key words: transformer; gases dissolved in oil; prediction; supervised learning; sequential learning

0 引言

变电站高压设备的安全运行是电力系统稳定可靠的基础。在运行过程中实时检测变压器的状态,对变压器的早期潜伏性故障进行评估预测,对提高设备的安全性和经济性具有十分重要的意义^[1-3]。

在线监测是对变压器绝缘健康状况进行实时监测的有效手段之一,可根据对设备的状态评估给出相应检修策略,从而实现电网的智能化和检修模式由定期检修向状态维修的转变^[4-6]。随着在线监测采集、计算机、信息处理、电力大数据等技术的发展,在线监测已走向实用化阶段,为保证电力变压器的

收稿日期:2019-05-20; 修回日期:2019-07-24

基金项目:福建省科技厅引导性项目(2017H0001)。

Project Supported by Natural Science Foundation of Fujian Province of China(2017H0001).

正常运行提供了保障。

近年来,变压器的故障诊断技术受到广泛关注,其中油中溶解气体分析技术(dissolved gas analysis, DGA)因具有无需变压器退出运行、不受电磁影响、能够及时发现变压器早期故障等特点而成为变压器维护和进行故障诊断最主要的技术手段^[7-9]。变压器油中溶解气体在线监测技术开发较早,目前已较为成熟,应用非常广泛。据统计,截止2019年5月,福建省网油中溶解气体在线监测装置共安装975台,覆盖率52%。相比于离线油中溶解气体色谱检测,油中溶解气体在线检测技术的优势有:①能够实时监测变压器等充油电气设备内部绝缘油的状态;②可将测得的大量数据上传后台的分析系统进行深入分析判断;③分析响应速度快,耗时短;④油样采集、组分分析、信号传输实现全自动,无需人工干预,减少测试误差^[10-11]。

根据在线监测系统提供的变压器油中溶解气体体积分数历史数据,预测未来气体体积分数及其发展趋势,是DGA故障预测的关键、在线监测的必要补充和提前预警变压器故障的重要手段。随着神经网络、灰色模型、遗传算法和专家系统等智能理论的发展,油中溶解气体体积分数预测成为变压器诊断领域的研究热门。目前,已报道的DGA在线预测工作主要集中于简单的机器学习算法(浅层神经网络、支持向量机等)^[12-16],和简单的深度学习算法(深度置信网络和深度自编解码网络)^[17-19]。石鑫^[17]等结合电力变压器在线监测油色谱数据特征及故障类型,使用深度自编解码网络检测故障。代杰杰^[18]等尝试使用4层深度置信网络预测油中溶解气体浓度,取得很好的效果。齐波^[19]等改进深度置信网络来解决溶解气体预测中存在的“时移”误差。但是上述工作存在几个问题:①大部分模型是在单个变压器小数据集上进行验证,数据规模仅几十至几百个,模型泛化性差,不具有普遍的适用价值;②大多数现有模型的假设样本之间是独立同分布的,几乎不考虑时间序列模型,然而现实中变压器油中溶解气体样本具有很强的时间相关性。

为了解决上述问题,文中系统分析了变压器油中溶解气体体积分数预测工作,全面比较了非时序有监督学习算法和时序学习算法,建立和发布了一个大规模数据集以供后来研究者使用,并在这个数据集上验证模型的有效性,对变压器的绝缘故障预报具有重要的现实意义。

1 溶解气体序列预测的问题定义

假设一个变压器 t 时刻的某一种溶解气体体积

分数表示成一个标量 x_i 。采样 M 个历史时刻的数据组成一个时间序列向量 $x=(x_1, \dots, x_M)$ 。文中的目标是通过学习历史数据找到一个模型 H 来预测未来数据 $y \in R^K$,即 $H: R^M \rightarrow R^K$,一般 $K < M$, K 是个常量,表示所需预测未来值的个数。

1.1 非时序有监督学习方法

目前大多数的方法都是直接使用传统的非时序有监督学习方法进行预测,如线性回归、浅层神经网络、支持向量机等。这种方法认为历史数据是当前数据的线性组合(线性回归模型)或非线性模型(浅层神经网络),即把 x 按时间先后顺序平均分解成 n 份,每一份含有 $m+1$ 个数据,其中前 m 个数据(把历史数据作为特征向量 x')用于输入模型 H ,最后一个数据是标签数据 y' ,即 $K=1$ 。把特征向量 x 按照时间顺序堆叠起来形成特征矩阵 $X' \in R^{n \times m}$,同时把标签 y' 堆叠起来形成标签向量 $y' \in R^K$ 。

非时序有监督学习模型优化可以转换为式(1)的求解

$$\bar{\beta} = \arg \min_{\beta} l[y', H(X'; \beta)] + \lambda \Phi(\beta) \quad (1)$$

式(1)中: $\bar{\beta}$ 表示模型的参数 β 的估算值; $l(\cdot)$ 表示的模型的损失函数,支持向量机的损失函数为铰链损失^[20],浅层神经网络模型的损失函数一般为平方损失; $\Phi(\cdot)$ 表示正则化函数是为防止模型的过拟合,如果是 l_1 第一范数约束将产生稀疏解,或是第二范数约束 l_2 将产生比较稳定的解; λ 表示损失函数和正则化项的比重, λ 越大表示正则化项越重要。

非时序有监督学习方法的建模基于一个重要的假设,即样本是独立同分布。这种假设适用于不同变压器的油中溶解气体体积分数及同一变压器不具累积效应的溶解气体体积分数。但在绝大多数情况下,变压器的油中溶解气体体积分数是具有累积效应的^[13, 15]。另外这种模型时间不敏感,即按照行随机打乱特征矩阵 X 计算出来的 $\tilde{\beta}'$ 和未打乱的特征矩阵计算出来的 $\tilde{\beta}$ 相等,即 $\tilde{\beta}' = \beta$ 。相比之下,时间序列模型对于变压器溶解气体体积分数的预测是个更合理的选择。

1.2 时间序列学习方法

常用的时间序列模型有:自回归模型(auto regression, AR)、移动平均模型(moving average, MA)和自回归差分移动平均模型(autoregressive integrated moving average model, ARIMA)^[21]。其中,ARIMA是AR和MA的组合加上对原始数据的差分。AR和线性回归方法非常相似,即假设 $m+1$ 时刻的数据是前 m 个时刻的历史数据的线性组合 $y' = \beta X$ 。与AR不同的是,MA使用历史数据的误差来拟合未来数据。ARIMA建模时,需要设置三个参数: p 阶AR、 q

阶MA和 d 阶差分。一般采用自相关函数和偏自相关函数分别观察和确定 p 和 q ,也可通过AIC准则对 p 和 q 进行最佳估计;通过时间序列的散点图或折线图来观察和确定 d 。变压器中不同气体的平稳性各

不相同,见图1,横坐标是时间,纵坐标是气体体积分数(经过标准化后),氢气含量是平稳的,而甲烷、二氧化碳等都具有波动性。不同的变压器因所处环境不一样,其平稳性也不是固定不变的。




图1 变压器内气体体积分数随着时间变化图

Fig. 1 Plots of gases dissolved in oil in a transformer

确定时间序列分析模型的阶数后,就可以对ARIMA模型进行参数估计。模型的参数估计算法和有监督学习方法优化算法非常相似:当 X 维度比较小,且 $X'X'^T$ 是正定矩阵时使用最小二乘法;当 X 维度比较大,可以使用随机梯度下降或是L_BFGS^[22]。最后,ARIMA要针对模型的合理性进行检验:①参数估计值是否有显著性;②验证残差序列是否是白噪声序列。若这两项验证通过,则认为该模型是合理的,否则,应重新选取模型。

2 实验

2.1 文中实验环境

系统环境:MAC OS High Sierra;CPU: Intel Core i5处理器,16G内存;软件:python 2.7,sklearn。

2.2 评价指标

在线预测可以认为是一个回归的问题,评价指标可以是均方误差(mean square error, MSE),平均绝对值误差(mean absolute error, MAE), R 平方值(r -square, R^2)和对称平均绝对值误差比例(symmetric mean absolute percentage error, SMAPE)。文中使用MAE进行评价,该值大于等于0,越接近0说明模型的效果越好。

2.3 数据集

本数据集搜集7个不同变压器的在线监测数据,时间从2014年8月至2018年8月,每天取一次数据。每条数据包含11个属性:监测时间、装置状

态、一次设备状态、氢气测量值、一氧化碳测量值、二氧化碳测量值、甲烷测量值、乙烯测量值、乙炔测量值、乙烷测量值和总烃测量值($\mu\text{L/L}$)。装置状态表示在线监测装置的状态,值为“装置正常”和“通道异常”。一次设备状态表示变压器状态,值为“设备正常”、“设备报警”和“数据未上传”。乙炔体积分数分布同变压器设备状态箱型图见图2。状态1、2和3分别表示“正常”、“数据未上传”和“报警”3种状态,可以看出乙炔的分布对3种状态具有高判别性。




图2 乙炔体积分数分布同变压器状态类型箱型图

Fig. 2 Box-plot of the distribution of C_2H_2 over the transformer status

值得注意的是,不同变压器不同气体组分的分布不尽相同^[23],见图3(为了体现差异未归一化),文中需要分别对每个变压器每种气体进行建模和测试。某个变压器油中部分气体体积分数之间关系见图4。由图4可以看出,氢气相对独立于其他气体,含碳气体之间显示了弱相关性,相关值小于0.3,这也说明气体间单独建模的必要性。




图3 不同变压器甲烷气体体积分数变化图


Fig. 3 Plot of CH₄ in different transformers

图4 某个变压器内部气体的关系图

Fig. 4 Correlation between gases in a transformer

这7台变压器的每年离在线数据比对和装置校验结果均符合DL/T 1498.2—2016中的测量误差要求,准确度较高,因此,该数据集保留所有有效数据。首先删除“乙烯测量值”这列数据,因为乙烯的值都为0。然后删除少量数据获取不成功的行,这些行的数值上显示为“-”,装置状态显示“通道异常”,一次设备状态显示“数据未上传”,最终获得8 386条数据,每个变压器平均有1 198条数据。为了能够用历史数据预测未来数据,需要按时间升序对数据进行排序。最后,对同一个变压器的气体进行归一化。

2.4 时序数据分割方法

气体体积分数预测使用的是监督学习算法,需要把数据分割为训练集和验证集。目前,大多数时序数据的分割方法是基于传统机器学习的分割方法,即并行分割,见图5,这种方法把数据分割成两个独立的部分,一部分用于训练,另一部分用于测试。这种方面所需的计算力较小,但对于文中的数据,模型在验证集上的性能与在训练集上的性能是强相关的,并且与将来的实际模型性能几乎不具有相关性。所以文中使用的是前向分割,见图6,这种

方法是在完整数据集上训练和验证,但使用不同的时间跨度。验证用的时间跨度比训练用时间跨度前移一个或几个预测间隔,从而对数据进行增强,增加训练和验证数据量,提高验证模型的泛化性。具体地,先把数据按时间分成80%训练数据,用来训练模型;再把剩下的20%数据当作验证数据,用于测试模型性能。




图5 时序数据并行分割方法

Fig. 5 Side-by-side approach




图6 时序数据前向分割方法

Fig. 6 Walk-forward approach

2.5 非时序有监督方法 vs 时间序列方法

对于非时序有监督方法,文中简单地使用前20天数据预测作为输入样本,第21天数据作为输出样本。对于时间序列方法,文中采用BIC或AIC作为准则,自动选择输入样本的时长。单独训练和测试每个变压器的每种气体,从而获得49组气体预测数据,最后在7种气体维度上做平均值,结果见表1。文中使用以下几种算法:简单移动平均法(MA)、随机森林(random forest, RF)、LASSO、线性回归(linear regression, LR)、支持向量回归(support vector regression, SVR)、神经网络(neural network, NN)、决策树(decision tree, DT)、AR和ARIMA。

从表1可以看出:

1)时序方法比非时序有监督方法效果要好,MA和ARIMA在大部分气体预测中取得最佳效果。主要原因是非时序有监督方法假设样本之间是独立同分布的,而变压器溶解气体体积分数在一定范围内具有累积效应,时序数据前后具有强相关性。

2)ARIMA在氢气、一氧化碳和二氧化碳预测方面取得最好效果。一方面是大多数变压器的氢气含量平稳,另一方面也说明了氢气当前预测值不仅与历史数据有关系,还与历史数据之间的差值关系密切。图7是不同变压器不同气体通过BIC选择 p , d , q 值的统计,可以看出大部分预测值同3阶AR和1阶MA有紧密的联系。

表1 非时序监督学习算法和时间序列学习算法结果比较

气体名称	MA	RF	LASSO	LR	SVR	NN	DT	AR	ARIMA
氢气	0.132 9	0.138 8	0.135 6	0.161 4	0.132 1	0.131 7	0.142 0	0.137 3	0.130 8
一氧化碳	0.084 8	0.126 1	0.090 4	0.126 7	0.102 8	0.084 5	0.119 0	0.092 0	0.082 4
二氧化碳	0.047 9	0.082 4	0.050 9	0.090 4	0.066 8	0.048 7	0.080 0	0.048 5	0.046 6
甲烷	0.100 8	0.118 5	0.101 5	0.129 1	0.104 1	0.101 2	0.116 5	0.103 0	0.101 3
乙烷	0.134 2	0.139 0	0.138 3	0.155 1	0.136 0	0.132 5	0.142 1	0.141 2	0.135 7
乙炔	0.075 9	0.080 1	0.078 4	0.085 7	0.076 9	0.076 3	0.078 9	0.079 8	0.078 3
总烃	0.062 5	0.081 8	0.063 8	0.095 1	0.066 9	0.063 4	0.076 8	0.064 2	0.063 3




图7 ARIMA 参数选择直方图

Fig. 7 Histogram of best parameters in ARIMA models

3)简单的MA对大多气体的预测已经能够得到不错的结果,甚至好过一些复杂的、鲁棒性强的有监督学习模型,如RF和SVR。

4)在大多数非时序有监督学习中,具有更强非线性拟合能力的NN效果最好。这说明大多数变压器的气体历史数据同当前预测数据呈强非线性关系。

2.6 参数调节

参数的调节是机器学习中的重要部分,参数的好坏对结果影响很大。对上述所有模型的参数调节使用网格搜索方法,参数的设置分别为:RF子树的个数为[50, 100, 200, 300, 400, 500]; LASSO的惩罚因子λ取值为[0.000 1, 0.001, 0.01, 0.1, 1, 10]; SVR的惩罚因子C取值为[0.000 1, 0.001, 0.01, 0.1, 1, 10]; NN的隐含层神经元个数为[50, 100, 150, 200, 250, 300]; DT树的深度为[2, 3, 4, 5, 6, 7]; ARIMA模型p的范围为[3-10],d为[0-2],q为[0-2],步长都为1。

NN隐含层神经元个数同MAE的关系图见图8。神经元个数从50到150,模型处于欠拟合状态;神经元达到200,模型处于最佳状态;当神经元不断增加,模型容易出现过拟合;最好结果和最差结果的MAE相差达到0.035。样本窗口大小同NN效果变化图见图9。由图9可以看出,窗口大小对模型影响相对小,当窗口大小为20时,模型获得最好的




图8 隐含层神经元个数变化对NN效果的影响

Fig. 8 Performance of NN with regards to the number of neuron in hidden layer




图9 样本窗口大小变化同NN效果的影响

Fig. 9 Performance of NN with regards to length of window

2.7 样例学习

为了展示不同算法的气体预测效果,文中列出了ARIMA和LASSO算法的二氧化碳预测图。见图10,深色线代表实际值,浅色线代表预测值,相比于LASSO,ARIMA在数据随着时间剧烈跳变的情况下依然能够保持较低的误差。这是因为ARIMA能够学习样本之间的差分信息,对变化趋势具有更强的捕捉能力。




图10 ARIMA和LASSO的二氧化碳预测样例

Fig. 10 CO₂ prediction via ARIMA and LASSO

为了进一步展示 ARIMA 算法在训练集和测试集的预测效果,文中挑选一个变压器的 C₂H₆ 进行可视化。见图 11。图 11 中:深色线表示实际值,浅色线表示预测值。由图 11 可以看出,ARIMA 在训练集和测试集的预测效果相当,时间序列模型不存在过拟合的状况;然而,ARIMA 的总体效果还不够精确,存在改善和提高的空间。




图11 ARIMA在某个变压器的训练和测试样例

Fig. 11 Training and testing performance of ARIMA

3 结语

变压器油中溶解气体在线监测数据的预测研究对于全面、及时提供 DGA 信息有着重要的现实作用和意义。文中首先全面比较了非时序有监督学习和时间序列学习算法在变压器油中溶解气体预测的应用;然后搜集和发布了一个大规模油中溶解

气体数据样本,从而为算法提供一个较为全面的验证集,提高模型泛化性;最后,使用前向数据分割方法进行数据增强。大量的实验证明了在大部分情况下,时序方法比非时序有监督方法对变压器油中溶解气体的预测效果好。另外,由于气体体积分数分布不同,没有一种绝对方法在所有变压器所有气体体积分数的预测中均达到最好效果。因此,针对不同气体的预测应使用不同的方法。为进一步提高预测精度,作者将继续研究多变量时间序列模型和深度模型。

参考文献:

- [1] WANG M, VANDERMAAR A J, SRIVASTAVA K D. Review of condition assessment of power transformers in service[J]. IEEE Electrical Insulation Magazine, 2002, 18(6): 12-25.
- [2] 江秀臣, 盛戈皞. 电力设备状态大数据分析的研究和应用[J]. 高电压技术, 2018, 44(4): 1041-1050.
JIANG Xiuchen, SHENG Gehao. Research and application of big data analysis of power equipment condition[J]. High Voltage Engineering, 2018, 44(4): 1041-1050.
- [3] 陈维荣, 宋永华, 孙锦鑫. 电力系统设备状态监测的概念及现状[J]. 电网技术, 2000, 24(11): 12-17.
CHEN Weirong, SONG Yonghua, SUN Jinxin. Concept and present situation of condition monitoring of power system equipment[J]. Power System Technology, 2000, 24(11): 12-17.
- [4] 胡文平, 尹项根, 张哲. 电气设备在线监测技术的研究与发展[J]. 华北电力技术, 2003(2): 23-26.
HU Wenping, YIN Xianggen, ZHANG Zhe. Research and development of on-line monitoring technique for electric equipments[J]. North China Electric Power, 2003(2): 23-26.
- [5] 王少华, 叶自强, 梅冰笑. 输变电设备在线监测及带电检测技术在电网中的应用现状[J]. 高压电器, 2011, 47(4): 84-90.
WANG Shaohua, YE Ziqiang, MEI Bingxiao. Application status of online monitoring and live detection technologies of transmission and distribution equipment in electric network[J]. High Voltage Apparatus, 2011, 47(4): 84-90.
- [6] 邹建明. 在线监测技术在电网中的应用[J]. 高电压技术, 2007, 33(8): 203-206.
ZOU Jianming. Application of on-line monitoring technology on power grid[J]. High Voltage Engineering, 2007, 33(8): 203-206.
- [7] DE FARIA H, COSTA J G S, OLIVAS J L M. A review of monitoring methods for predictive maintenance of electric power transformers based on dissolved gas analysis[J]. Renewable and Sustainable Energy Reviews, 2015(46): 201-209.
- [8] DUVAL M. A review of faults detectable by gas-in-oil anal-

- ysis in transformers[J]. IEEE Electrical Insulation Magazine, 2002, 18(3): 8-17.
- [9] SAHA T K. Review of modern diagnostic techniques for assessing insulation condition in aged transformers[J]. IEEE Transactions on Dielectrics and Electrical Insulation, 2003, 10(5): 903-917.
- [10] 赵笑笑, 云玉新, 陈伟根. 变压器油中溶解气体的在线监测技术评述[J]. 电力系统保护与控制, 2009, 37(23): 187-191.
- ZHAO Xiaoxiao, YUN Yuxin, CHEN Weigen. Comment on on-line monitoring techniques for dissolved gas in transformer oil[J]. Power System Protection and Control, 2009, 37(23): 187-191.
- [11] 赵学民, 王 鑫, 赵哲军, 等. 油中溶解气体在线色谱监测技术在变压器运行中的应用[J]. 华北电力技术, 2007(10): 29-31.
- ZHAO Xuemin, WANG Xin, ZHAO Zhejun, et al. Application of on-line chromatograph monitoring of dissolved gases in oil on transformer operation[J]. North China Electric Power, 2007(10): 29-31.
- [12] 杨廷方, 刘 沛, 李 浙, 等. 应用新型多方法组合预测模型估计变压器油中溶解气体浓度[J]. 中国电机工程学报, 2008, 31(28): 108-113.
- YANG Tingfang, LIU Pei, LI Zhe, et al. A New combination forecasting model for concentration prediction of dissolved gases in transformer oil[J]. Proceedings of the CSEE, 2008, 31(28): 108-113.
- [13] 高少云. 电力变压器油色谱在线监测与预警系统研究[D]. 南昌: 华东交通大学, 2017.
- GAO Shaoyun. Power transformer oil chromatogram on-line monitoring and warning system research[D]. Nanchang: East China Jiaotong University, 2017.
- [14] 高 骏, 何俊佳. 量子遗传神经网络在变压器油中溶解气体分析中的应用[J]. 中国电机工程学报, 2010, 30(30): 121-127.
- GAO Jun, HE Junjia. Application of quantum genetic ANNs in transformer dissolved gas-in-oil analysis[J]. Proceedings of the CSEE, 2010, 30(30): 121-127.
- [15] 朱金海. 220 kV 变压器油色谱在线监测数据的准确性分析[D]. 厦门: 厦门理工学院, 2016.
- ZHU Jinhai. Research of the accuracy of oil chromatography online monitoring data on 220 kV transformer[D]. Xiamen: Xiamen University of Technology, 2010.
- [16] ILLIAS H A, ZHAO L W. Identification of transformer fault based on dissolved gas analysis using hybrid support vector machine-modified evolutionary particle swarm optimization [J]. Plos One, 2018, 13(1): e0191366.
- [17] 石 鑫, 朱永利, 宁晓光, 等. 基于深度自编码网络的电力变压器故障诊断[J]. 电力自动化设备, 2016, 36(5): 122-126.
- SHI Xin, ZHU Yongli, NING Xiaoguang, et al. Transformer fault diagnosis based on deep auto-encoder network[J]. Electric Power Automation Equipment, 2016, 36(5): 122-126.
- [18] 代杰杰, 宋 辉, 杨 伟, 等. 基于深度信念网络的变压器油中溶解气体浓度预测方法[J]. 电网技术, 2017, 41(8): 359-364.
- DAI Jiejie, SONG Hui, YANG Wei, et al. Concentration prediction of dissolved gases in transformer oil based on deep belief network[J]. Power System Technology, 2017, 41(8): 359-364.
- [19] 齐 波, 王一鸣, 张 鹏, 等. 面向变压器油色谱趋势预测的深度递归信念网络[J]. 电网技术, 2019, 43(6): 1892-1899.
- QI Bo, WANG Yiming, ZHANG Peng, et al. Deep recurrent belief network model for trend prediction of transformer DGA data[J]. Power System Technology, 2019, 43(6): 1892-1899.
- [20] VAPNIK V. Statistical learning theory[M]. New York: Wiley, 1998.
- [21] BOX G E P, JENKINS G M. Time series analysis forecasting and control[M]. New Jersey: A John Wiley & Sons INC., 1997.
- [22] BYRD R H, LU P, NOCEDAL J. A limited memory algorithm for bound constrained optimization[J]. SIAM Journal on Scientific and Statistical Computing, 1995, 16(5): 1190-1208.
- [23] 连鸿松. 油中气体含量对电容型设备绝缘性能的影响研究[J]. 电力电容器与无功补偿, 2017, 38(5): 96-101.
- LIAN Hongsong. Study on the influence of gas contents in the oil on the insulation performance of capacitive equipment[J]. Power Capacitor & Reactive Power Compensation, 2017, 38(5): 96-101.

刘慧鑫(1990—), 女, 工程师, 博士, 主要从事高压电器状态监测与故障诊断方面的研究工作。

张江龙(1987—), 男, 工程师, 博士, 主要从事机器学习、深度学习和多媒体内容分析方面的研究工作(通讯作者)。