

基于LSTM网络的变压器油中溶解气体浓度预测^{*}王科¹ 苟家冀² 彭晶¹ 刘可真² 田小航³ 盛戈峰⁴(1.云南电网有限责任公司电力科学研究院 昆明 650217; 2.昆明理工大学 电力工程学院 昆明 650504;
3.云南电力技术有限责任公司 昆明 650000; 4.上海交通大学 电气工程系 上海 200240)

摘要: 电力变压器作为电力系统中传输和变换电能的主要设备,其安全稳定运行在电网中起着重要的作用。对变压器油中溶解气体浓度变化的趋势进行预测,可为其运行状态评估提供重要依据,鉴于此提出了一种基于长短期记忆网络(LSTM)的变压器油中溶解气体浓度预测模型。该模型克服了传统神经网络在序列预测方面存在的“梯度消散”问题,利用油中溶解气体的序列数据对长短期记忆网络进行训练,得到最优的预测模型参数。以变压器油中溶解的7种特征气体浓度为输入,以预测气体的浓度为输出。通过算例分析表明,相比于传统的机器学习预测方法支持向量机(support vector machine, SVM)与反向传播神经网络(back propagation neural network, BPNN),本文所提的LSTM预测模型更能准确地预测油中溶解气体的浓度。

关键词: 变压器;油中溶解气体;长短期记忆网络;预测

中图分类号: TM411, TP183 **文献标识码:** A **国家标准学科分类代码:** 470.4037

Prediction of dissolved gas concentration in transformer oil
based on LSTM networkWang Ke¹ Gou Jiaji² Peng Jing¹ Liu Kezhen² Tian Xiaohang³ Sheng Gehao⁴(1. Electric Power Research Institute, Yunnan Power Grid Co., Ltd., Kunming 650217, China;
2. Faculty of Electric Power Engineering, Kunming University of Science and Technology, Kunming 650504, China;
3. Yunnan Electric Power Technology Co., Ltd., Kunming 650000, China;
4. Department of Electrical Engineering, Shanghai Jiaotong University, Shanghai 200240, China)

Abstract: Power transformers play an important role in the safe and stable operation of the power grid as the main equipment for transmitting and transforming electrical energy in power systems. Predicting the trend of dissolved gas concentration in transformer oil can provide an important basis for its operational status assessment. In view of that, a long-short-term memory network (LSTM) based prediction model for dissolved gas concentration in transformer oil is proposed. The model overcomes the problem of “gradient dissipation” in sequence prediction of the traditional neural networks. It uses the sequence data of dissolved in oil to train the long-short-term memory in order to obtain the optimal prediction model parameters. The model sets the concentration of the seven characteristic gases dissolved in the transformer oil as input, and the concentration of the gas to be predicted as output. The example analysis shows that Compared with traditional machine learning prediction methods, support vector machine (SVM) and back propagation neural network (BPNN), the LSTM prediction model can predict the concentration of dissolved gases in oil more accurately.

Keywords: transformer; dissolved gas in oil; Long short-term memory network; prediction

0 引言

电力变压器作为电力系统中最为核心的设备,起着分配、传输电能的重要作用,是电网公司的重要资产,其安全

稳定运行是保障电网可靠性供电的前提。变压器正常运行情况下,由于内部绝缘固体的老化会产生少量气体溶解于绝缘油中,主要有氢气(H_2)、甲烷(CH_4)、乙烷(C_2H_6)、乙烯(C_2H_4)、乙炔(C_2H_2)、一氧化碳(CO)、二氧化碳(CO_2)

收稿日期:2019-08-06

^{*}基金项目:国家自然科学基金资助项目(51477100);云南电网有限责任公司科技项目(YNKJXM20180736)资助

等气体^[1]。根据油中溶解气体含量比例的不同可判别变压器的不同运行状况^[2-3],例如:产生高能放电时氢气(H_2)和乙炔(C_2H_2)的含量会增加;遇到强烈磁场的情况下,烃类气体的含量会增加,且表现出一定的关联。因此对变压器油中溶解气体进行分析(dissolved gas analysis, DGA)对变压器的运行状况判别有着重要作用^[4-5]。

目前国内外大量学者对变压器油中溶解气体的预测进行了大量研究,文献[6]利用灰色模型(grey model, GM)残差修正融合算法对变压器油中气体进行分析预测,其融合了自适应回归算法和马尔可夫修正模型提高了预测精度;文献[7]基于核目标度量规则(kernel target alignment, KTA)和支持向量机(support vector machines, SVM)网络模型对油中溶解气体进行了预测分析;文献[8]利用灰色关联分析方法确定了待预测气体关键参量,建立了基于(K-nearest neighbor, KNN)回归的多因素预测模型,实现了变压器油中溶解气体体积分数的预测。由于传统的离线 DGA 方法存在周期较长、误差大等特点^[9],不能及时预测分析溶解气体的浓度,故会对变压器的运行状况产生延迟判断,导致经济损失。近年来随着人工智能算法的快速崛起,机器学习的方法已被广泛应用于预测变压器的运行状况^[10-11],主要有操作简单,稳定性好,预测误差小等优点。循环神经网络(RNN)因为其自身具有“记忆”功能^[12-14],已被广泛应用于处理时间序列的预测模型中,并取得了明显效果,但由于 RNN 网络模型在预测过程中存在“梯度消散”的问题,无法解决较长时间跨度序列建模的问题。

鉴于此,本文提出了一种基于长短期记忆网络(long short-term memory, LSTM)的变压器油中溶解气体浓度的预测模型^[15-16],通过对(RNN)隐藏层中的细胞进行替换,使其具有较强的“记忆”功能,它克服了传统 RNN 网络预测模型存在的“梯度消散”问题,可以处理较长时间的非线性序列预测问题^[17-18]。利用该模型对变压器油中溶解气体浓度进行预测分析,实验结果验证了该模型有着较高的预测准确率。

1 LSTM 循环神经网络

LSTM 是长短期记忆网络, LSTM 算法最早由 Hochreiter 和 Schmidhuber 为了解决循环神经网络(RNN)无法较长时间跨度序列建模问题而提出^[13-14]。LSTM 是目前最成熟的 RNN 架构,因其本身具有更好的特征提取和学习能力,被广泛应用在处理长时间序列预测的问题上。

1.1 循环神经网络(RNN)网络模型

RNN 由输入层、1 个隐藏层和 1 个输出层构成,其结构模型及隐藏层细胞结构如图 1 所示。

给定的已知序列 $x = [x_1, x_2, \dots, x_n]$ 应用于 1 个标准 RNN 模型中,结合迭代式(1)~式(2)可推导出一个隐藏层序列 $s = [s_1, s_2, \dots, s_n]$ 和一个输出层序列 $y = [y_1, y_2, \dots, y_n]$ 。

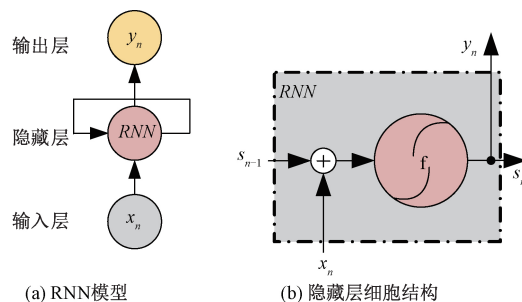


图 1 RNN 模型及隐藏层细胞结构

$$s_t = f(W_{ss}s_{t-1} + W_{xs}x_t + b_s) \quad (1)$$

$$y_t = W_{ys}s_t + b_y \quad (2)$$

式中: W 代表权重系数矩阵(W_{xs} 表示输入层到隐藏层的权重系数矩阵); b 为各层偏置向量; f 为激活函数(常见的有 sigmoid 、 \tanh 、 ReLU 等函数); t 表示具体时刻。将 RNN 中隐藏层的细胞替换为 LSTM 细胞,使其具有记忆功能,可有效解决 RNN 在处理长时序数据过程中存在的问题。

1.2 LSTM 循环神经网络

LSTM 的网络结构由输入门、遗忘门、输出门共同构成^[19-21]。网络结构如图 2 所示,传输数据的输入、遗忘与输出分别由 3 个单独的门限单元格来控制, t 表示当前时刻。输入门利用 sigmoid 函数和 \tanh 函数录入和校正参数,将变量数据映射至 $[0, 1]$ 之间,不同值对应信息是否应该通过, 0 表示禁止信息输出, 1 表示允许信息输出;遗忘门是将上一时刻神经元状态选择性遗忘;输出门是用来输出和校正参数。




图 2 LSTM 网络基本单元结构

图 2 中,输入门中的 x_t 经激活函数 \tanh 变化后决定记忆模块中的保留参数;记忆单元遗忘部分由遗忘门输入 x_t 、记忆单元 s_{t-1} 和输出值 h_{t-1} 共同决定;输出门中的 h_t 由 s_t 和 o_t 决定,计算公式如式(3)~(8)所示。

$$i_t = \sigma(W_{ix}x_t + W_{ih}h_{t-1} + b_i) \quad (3)$$

$$f_t = \sigma(W_{fx}x_t + W_{fh}h_{t-1} + b_f) \quad (4)$$

$$o_t = \sigma(W_{ox}x_t + W_{oh}h_{t-1} + b_o) \quad (5)$$

$$g_t = \varphi(W_{gx}x_t + W_{gh}h_{t-1} + b_g) \quad (6)$$

$$h_t = \phi(s_t) \odot o_t \quad (7)$$

$$S_t = g_t \odot i_t + S_{t-1} \odot f_t \quad (8)$$

式中: i_t, f_t, o_t 分别表示输入门、遗忘门和输出门的状态计算结果; W_{ix}, W_{fx}, W_{ox} 分别表示输入门、遗忘门和输出门的权重矩阵; b_i, b_f, b_o 分别表示相应门的偏置项; σ 代表 *sigmoid* 变量函数; \tanh 表示双曲正切激活函数; φ 表示函数变化; \odot 表示各元素按位置相乘。

1.3 LSTM 循环神经网络的训练学习

LSTM 循环神经网络的训练包括实时循环学习和随时间反向传播两种算法。相较于实时循环学习算法在训练过程中的变量分类不清、效率低, 随时间反向传播算法具有特征参量分类明确、训练效率更高等优势, 故本文所述的 LSTM 网络采用随时间反向传播算法进行模型训练, LSTM 网络时序图如图 3 所示, 具体步骤如下:




图 3 LSTM 网络时序

1) 前向计算每个记忆神经元的输出值;

2) 反向计算每个记忆神经元的误差项, LSTM 误差项包括不同网络层之间与时间序列两方面反向传播;

3) 根据误差项计算每个权重的梯度。

2 基于 LSTM 网络的变压器油中溶解气体浓度预测实现过程

2.1 LSTM 网络模型的构建过程

本文所提的 LSTM 预测变压器油中溶解气体浓度的模型如图 4, 具体步骤如下:

1) 收集变压器在线色谱样本数据, 取特征参量 H_2 、 CH_4 、 C_2H_6 、 C_2H_4 、 C_2H_2 、 CO 、 CO_2 的浓度作为模型的输入。

2) 将各特征参量的样本数据采用 min-max 归一化处理, 映射到 $[0, 1]$ 之间, 其转化函数为 $x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$, 其中: x_{\min} 为样本数据最小值, x_{\max} 为样本数据最大值, x 为转化前的样本数据, x^* 为转换后的样本数据; 划分数据集的前 80% 为训练集, 20% 为测试集。

3) 对归一化处理后的特征参量 X_1, X_2, \dots, X_n 分别进行 LSTM 模型的训练、测试, 保证在预测结果评价标准误差较小的情况下, 确定训练好的最优模型参数, 完善模型。

4) 由 Step3 得到的完整模型对测试数据集进行预测, 得到预测结果 P_1, P_2, \dots, P_n 。

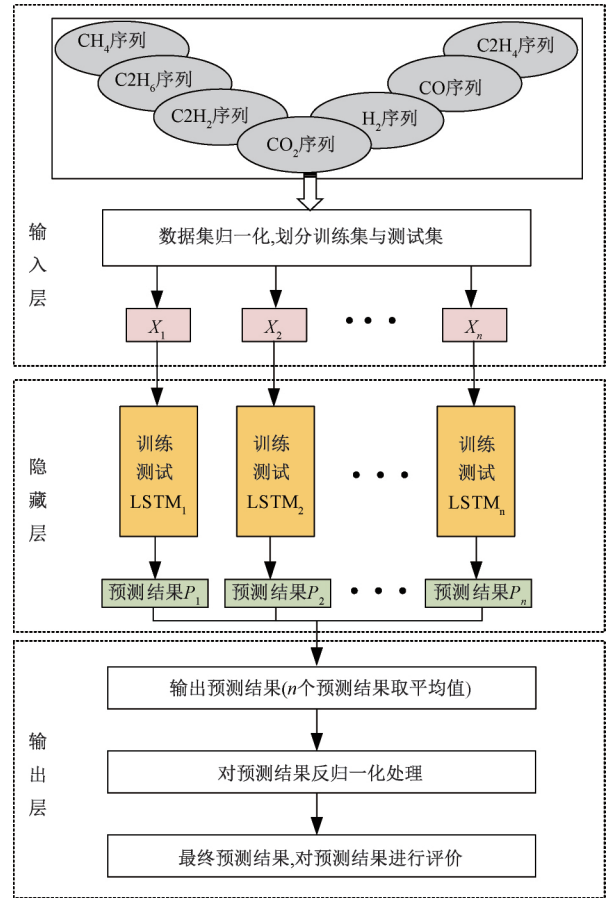


图 4 LSTM 网络预测模型

5) 本模型输出采用以平均值的方式计算 n 个预测结果, 并进行反归一化处理得到最终的预测结果, 最后结合实验评价指标对预测结果进行评价分析。

2.2 实验评价指标

为了准确评估本文所提的 LSTM 预测模型的性能, 本文预测评价准则采用平均相对百分误差 y_{MAPE} 、根均方误差 y_{RMSE} 和预测精度 y_{FA} 3 项指标, 如式(9)~(11)所示。

$$y_{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{X_{act}(i) - X_{pred}(i)}{X_{act}(i)} \right| \quad (9)$$

$$y_{RMSE} = \sqrt{\frac{\sum_{i=1}^n (X_{act}(i) - X_{pred}(i))^2}{n}} \quad (10)$$

$$y_{FA} = \left(1 - \frac{|X_{act}(i) - X_{pred}(i)|}{X_{act}(i)} \right) \times 100\% \quad (11)$$

式中: n 表示预测总次数; $X_{act}(i)$ 和 $X_{pred}(i)$ 分别为 i 时刻油中溶解气体浓度的真实值和预测值。

3 算例分析

3.1 数据集划分

为验证本文提出的预测变压器油中溶解气体浓度 LSTM 模型的可靠性, 以某 220 KV 变压器油色谱在线监

测数据为例,样本数据为 2017 年 8 月 1 日~2018 年 4 月 10 日,共计 250 组检测数据,检测周期为 1 天。将 2017 年 8 月 1 日~2018 年 1 月 20 日共 200 组监测数据作为训练集,将 2018 年 1 月 21 日~2018 年 4 月 10 日共 50 组数据作为测试集,不同模型的训练集与测试集数据容量如表 1 所示。

表 2 给出了 10 组样本数据示例,本文以乙烯(C_2H_4)浓度的预测结果为例进行说明,将预测结果与经典的 SVM

表 1 训练集与测试集容量对比

模型	训练样本数	测试样本数
LSTM	200	50
BPNN	200	50
SVM	200	50

网络模型和 BPNN 网络模型进行对比,通过评价指标分析,表明本文所提的预测方法有更高的预测准确率,文中所有检测数据的单位为 $\mu L/L$ 。

表 2 样本示例

(单位: $\mu L/L$)

日期	H_2	CH_4	C_2H_6	C_2H_4	C_2H_2	CO	CO_2
2017-08-01	18.66	5.50	2.06	10.49	4.05	143.10	1310.96
2017-08-02	18.32	5.29	1.92	10.11	3.97	138.34	1224.88
2017-08-03	18.84	5.50	2.09	10.63	4.16	144.09	1333.92
2017-08-04	19.27	5.69	2.26	11.01	4.31	148.71	1405.61
2017-08-05	17.82	5.20	1.99	10.27	4.05	137.46	1248.00
2017-08-06	18.24	5.24	2.06	10.21	3.96	137.15	1248.66
2017-08-07	18.23	5.18	1.88	10.20	3.959	138.32	1226.77
2017-08-08	18.41	5.27	2.00	10.26	3.99	141.24	1256.72
2017-08-09	18.66	5.34	2.03	10.51	4.09	142.98	1300.75
2017-08-10	18.56	5.32	2.06	10.45	4.06	144.43	1299.44

3.2 异常数据处理

历史变压器油色谱在线数据由于检测环境的差异或者数据丢失,存在异常数据,影响本模型的预测精度,根据文献[22]提供的插值方法来处理样本数据中的异常数据,确保预测模型的精度。

3.3 试验环境设置

Keras 可以提供方便的编程接口,方便用户快速掌握神经网络的结构,减少编程中重复性工作,具有模块化、支持训练模型层的自由组合等优点,故本文实验采用 Keras 实现基于 LSTM 神经网络模型的变压器油中溶解气体预测,硬件条件是:CPU 为 intel(R) Xeon(R) E5-1660,主频为 3.6 GHz,内存为 8 GB,编程语言为 Python3.5。

本文涉及的 LSTM 预测模型通过控制变量的方法使预测效果达到最优,输入数据为 6 维,步长为 1,预测模型隐藏层中激活函数使用 *ReLU* 函数,适用于时间序列非线性预测,初始学习率设置为 0.001,每一层网络节点的舍弃率为 0.2,防止过度拟合,迭代次数取 200,其中输入层与输出层之间神经元的个数由训练集的特征决定,神经元的个数设置的太多或者太少,都会影响最终预测精度,通常采用经验公式确定初始神经元的个数,经过训练集试验后,结合评价标准确定误差最小的神经元个数,根据文献[23]可得隐藏层神经元个数 M 的经验公式为:

$$M = \sqrt{(n+m)} + a, \quad (12)$$

式中: n 和 m 分别为输出层和输入层的节点数, a 为 $[0,10]$

之间的常数,通过训练集数据实验可知,在评价指标最优的前提下可得本文选取神经元的个数为 10,不同层数的 LSTM 训练网络对预测结果精度不一样,表 3 是在控制神经元个数为 10 不变的情况下,逐步增加网络层数来测试模型,最后结合平均相对误差的评价指标,选取本文的网络层为 2。

表 3 模型组合结构实验结果

LSTM 网络层数	神经元个数	特征数	平均相对 误差
1	10	7	1.975
2	10	7	0.735
3	10	7	2.014
4	10	7	2.581

同时,利用训练集样本数据构建 BPNN 网络与 SVM 网络预测模型,其中 BPNN 网络模型中激活函数使用 *tansig*,初始学习率设置为 0.001,隐藏层单元数为 16,训练次数 200 次;SVM 网络模型中采用径向核函数(RBF),其中核参数为 8.4193,惩罚因子 C 取 1.0。

3.4 LSTM 回归模型预测结果

本节采用 LSTM 网络预测模型对油中溶解气体含量进行预测,实验研究的测试结果如表 4 所示。图 5 是利用 50 组测试集对不同算法模型乙烯浓度的预测值与真实值

对比的折线图。从图中可以看出,所涉及的 3 种算法模型均有较好的预测性能,本文所提的 LSTM 预测模型有更好的预测效果,对于实际数据有着更好的拟合能力,得到的预测曲线精度最高,与实际气体含量变化趋势基本一致。

表 4 LSTM 模型预测 C₂H₄ 浓度的结果

编号	真实值 ($\mu\text{L/L}$)	LSTM 预测值 ($\mu\text{L/L}$)	相对误差 (%)	编号	真实值 ($\mu\text{L/L}$)	LSTM 预测值 ($\mu\text{L/L}$)	相对误差 (%)
1	8.953	8.869	0.944	26	10.112	10.170	0.570
2	9.795	9.839	0.443	27	10.498	10.496	0.014
3	9.263	9.225	0.409	28	10.189	10.246	0.557
4	9.978	9.916	0.623	29	9.980	9.892	0.884
5	10.129	10.126	0.035	30	10.549	10.609	0.573
6	9.586	9.739	1.591	31	9.609	9.575	0.348
7	10.104	10.193	0.879	32	10.303	10.246	0.557
8	10.365	10.352	0.128	33	11.009	11.119	0.998
9	10.006	9.867	1.385	34	10.823	10.782	0.380
10	10.161	10.074	0.854	35	10.612	10.624	0.116
11	10.295	10.191	1.010	36	10.350	10.285	0.633
12	9.749	9.766	0.174	37	10.697	10.751	0.499
13	10.186	10.107	0.779	38	10.854	11.022	1.547
14	10.653	10.642	0.105	39	8.785	8.878	1.060
15	10.068	10.054	0.137	40	8.883	8.848	0.395
16	10.984	11.004	0.188	41	9.024	9.144	1.337
17	10.621	10.567	0.509	42	8.955	9.007	0.589
18	10.450	10.454	0.037	43	10.121	10.084	0.368
19	10.512	10.499	0.123	44	10.104	10.086	0.180
20	10.263	10.284	0.197	45	9.356	9.261	1.015
21	10.203	10.125	0.759	46	9.178	9.838	7.189
22	10.219	10.256	0.365	47	9.890	9.890	0.005
23	10.278	10.194	0.819	48	10.936	10.827	0.999
24	11.010	11.034	0.224	49	10.554	10.429	1.181
25	10.634	10.667	0.306	50	11.178	11.202	0.211
平均相对误差		0.705%		最大相对误差		7.189%	




图 5 乙烯 C₂H₄ 浓度预测曲线与实际曲线对比图

结合评价指标,将本文所提的 LSTM 网络预测模型与 支持向量机(support vector machine, SVM)与反向传播神

神经网络(back propagation neural network, BPNN)预测方法进行对比,结果如表 5 所示,LSTM 预测的平均相对误差为 0.705%,预测精度为 99.295,基于 LSTM 网络模型预测方法无论在平均相对误差、根均方误差和预测精度方面均优于其他 2 种方法,预测效果更好。

表 5 不同模型预测结果对比

模型	平均相对误差	根均方误差	预测精度
	$y_{MAPE} / (\%)$	$y_{RMSE} / (\%)$	y_{FA}
LSTM	0.705	0.117	99.295
SVM	3.511	0.439	96.489
BPNN	4.165	0.497	95.835

同理,采用 LSTM 预测模型以 2017 年 8 月 1 日~2018 年 4 月 10 日之间的数据为例,对其他几种气体浓度进行预测,结果如表 6 所示;可知本文所提的 LSTM 预测模型的平均相对误差和预测精度均低于 SVM、BPNN 预

测方法,具有较高的可靠性。

表 6 其他气体浓度预测结果

气体类别	平均相对误差 $y_{MAPE} / (\%)$			预测精度 y_{FA}		
	LSTM	SVM	BPNN	LSTM	SVM	BPNN
H ₂	1.494	4.223	3.128	99.106	95.327	96.135
CH ₄	2.469	6.831	5.821	98.769	92.358	94.183
C ₂ H ₆	2.496	6.856	7.384	98.327	92.267	93.183
C ₂ H ₂	1.988	5.522	6.381	98.926	94.026	94.158
CO	2.463	4.945	3.253	98.749	95.128	95.859
CO ₂	2.861	5.931	4.189	97.831	93.896	95.564

表 7 为测试样本集在三种算法模型下连续 20 天的乙烯浓度实际值和预测值及绝对百分比误差的汇总表,从表中我们可以看出 LSTM 网络模型预测的平均误差为 0.600,均小于 SVM 与 BPNN 预测模型的平均误差,表明本文所提的 LSTM 模型预测结果误差最小,与实际值最符合。

表 7 实际值和预测值及绝对百分比误差

日期/ d	真实值/ ($\mu\text{l/L}$)	LSTM 网络模型		SVM 网络模型		BPNN 网络模型	
		预测值/ ($\mu\text{l/L}$)	绝对百分比误差/ (%)	预测值/ ($\mu\text{l/L}$)	绝对百分比误差/ (%)	预测值/ ($\mu\text{l/L}$)	绝对百分比误差/ (%)
1	8.953	8.869	0.944	8.669	3.172	8.518	4.863
2	9.263	9.225	0.409	8.878	4.156	8.81	4.886
3	10.129	10.126	0.035	10.394	2.611	10.549	4.15
4	10.104	10.193	0.879	10.462	3.543	9.737	3.634
5	10.006	9.867	1.385	10.352	3.458	9.399	6.065
6	10.295	10.191	1.010	9.913	3.711	9.692	5.851
7	10.186	10.107	0.779	9.873	3.073	9.875	3.05
8	10.068	10.054	0.137	10.107	0.387	10.381	3.11
9	10.621	10.567	0.509	10.287	3.143	10.956	3.15
10	10.512	10.499	0.123	10.344	1.598	10.973	4.39
11	10.203	10.125	0.759	10.545	3.352	9.631	5.599
12	10.278	10.194	0.819	9.969	3.006	9.776	4.884
13	10.634	10.667	0.306	10.384	2.351	10.193	4.145
14	10.498	10.496	0.014	9.883	5.85	10.265	2.219
15	9.980	9.892	0.884	10.314	3.343	10.349	3.697
16	9.609	9.575	0.348	10.048	4.576	10.166	5.799
17	11.009	11.119	0.998	10.238	7.001	10.668	3.096
18	10.612	10.624	0.116	10.376	2.223	10.17	4.165
19	10.697	10.751	0.499	10.431	2.487	10.268	4.015
20	8.785	8.878	1.060	9.344	6.358	9.376	6.727
平均误差/(%)	—	—	0.600	—	3.469	—	4.375
最大误差/(%)	—	—	1.385	—	7.011	—	6.727

4 结 论

本文针对变压器油中溶解气体浓度的预测,提出了基于 LSTM 的 DGA 预测模型,通过实际的算例分析进行验证,主要有以下结论:

1)该 LSTM 模型克服了传统神经网络(RNN)在信息处理方面存在的“梯度消散”问题,有效解决长时间处理非线性序列问题。

2)本文所提的基于 LSTM 变压器油中溶解气体浓度预测可以更好地拟合实际气体浓度,验证了所提方法的有效性。

3)LSTM 网络模型相对于传统的 SVM、BPNN 机器学习方法,在同样的训练集与测试集条件下,其预测平均相对误差更低,预测精度更高。

4)下一步将重点研究 LSTM 网络模型参数的改进与优化,进一步提高预测的准确率。

参考文献

- [1] 代杰杰,宋辉,杨祎,等.基于深度信念网络的变压器油中溶解气体浓度预测方法[J].电网技术,2017,41(8):2737-2742.
- [2] 代杰杰,宋辉,杨祎,等.基于油中气体分析的变压器故障诊断 ReLU-DBN 方法[J].电网技术,2018,42(2):658-664.
- [3] 廖怀东,李海威.变压器油色谱分析及故障判断[J].电力建设,2003(10):25-26,29.
- [4] 荣智海,齐波,李成榕,等.面向变压器油中溶解气体分析的组合 DBN 诊断方法[J].电网技术,2019(10):3800-3808.
- [5] 魏云冰,王东晖,邵秋华,等.一种电力变压器油中溶解气体的标定新方法[J].电测与仪表,2016,53(1):122-128.
- [6] 吴汶捷,何怡刚,段嘉璐,等.油中溶解气体的灰色模型残差修正融合算法[J].电子测量与仪器学报,2018,32(10):87-94.
- [7] 唐勇波,丰娟.KTA-SVM 的变压器油中溶解气体浓度预测[J].控制工程,2017,24(11):2263-2267.
- [8] 刘航,王有元,梁玄鸿,等.基于多因素的变压器油中溶解气体体积分数预测方法[J].高电压技术,2018,44(4):1114-1121.
- [9] 杨廷方,刘沛,李浙,等.应用新型多方法组合预测模型估计变压器油中溶解气体浓度[J].中国电机工程学报,2008,28(31):108-113.
- [10] 宇炜,郭剑波,吴文传,等.数据-知识融合的机器学习(1):模型分析[J].中国电机工程学报,2019(15):4406-4416.
- [11] 周志华.机器学习[M].北京:清华大学出版社,2016.
- [12] HUANG P, HIM M, HASEGAWA J M, et al. Joint optimization of masks and deep recurrent neural networks for monaural source separation[J]. IEEE/ACM Transactions on Audio, Speech and Language Processing, 2015, 23(12): 2136-2147.
- [13] 李俊峰.基于循环神经网络和蝙蝠算法的变压器故障诊断[J].电工技术,2018(20):38-41.
- [14] 陈涵,邓长虹,李大路.基于循环神经网络的动态等值模型辨识[J].高电压技术,2008(5):1001-1004.
- [15] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [16] SUNDERMEYER M, NEY H, SCHLUTER R. From feedforward to recurrent LSTM neural networks for language modeling[J]. IEEE/ACM Transactions on Audio, Speech and Language Processing, 2015, 23(3): 517-529.
- [17] 陈卓,孙龙祥.基于深度学习 LSTM 网络的短期电力负荷预测方法[J].电子技术,2018(1):39-41.
- [18] 杨甲甲,刘国龙,赵俊华,等.采用长短期记忆深度学习模型的工业负荷短期预测方法[J].电力建设,2018,39(10):20-27.
- [19] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9(8): 1735-1780.
- [20] LI D, QIAN J. Text sentiment analysis based on long short-term memory[C]. 2016 First IEEE International Conference on Computer Communication and the Internet, 2016: 489-493.
- [21] GRAVES, ALEX, MOHAMED, et al. Speech recognition with deep recurrent neural networks[C]. 2013 IEEE International Conference on Acoustics, Speech and Signal Processing, 2013: 6645-6649.
- [22] 于亚龙,穆远彪.插值算法的研究[J].现代计算机(专业版),2014(5):32-35.
- [23] 权波,杨博辰,胡可奇,等.基于 LSTM 的船舶航迹预测模型[J].计算机学,2018,45(S2):126-131.

作者简介

王科,高级工程师,硕士,主要研究方向为高电压试验技术工作。

E-mail: 405043987@qq.com

刘可真(通信作者),教授,博士,主要研究方向为电力系统分析和继电保护科研工作。

E-mail: liukzh@foxmail.com